Settimana 5 — Bortkiewicz e i calci di cavallo: distribuzione geometrica e distribuzione di Poisson

Quante prove servono prima che qualcosa riesca? Quanti eventi capitano mentre osserviamo un sistema? Due domande vicine, due modi diversi di costruire una variabile aleatoria.

Apri Slide della Lezione

Il percorso e ciò che è richiesto all'esame

Questa settimana impariamo a descrivere due situazioni che incontriamo continuamente quando osserviamo un sistema:

- **un'attesa**: «quante volte devo riprovare prima che vada bene?»;
- **un conteggio in un intervallo**: «quanti eventi si verificano mentre guardo?».

Per ciascuna costruiremo un modello probabilistico: dichiareremo le ipotesi con cui rappresentiamo la situazione e ricaveremo la distribuzione della variabile che ci interessa. Prima, però, ci serve un nuovo strumento da affiancare al valore atteso: la **varianza**, che misura quanto i risultati si disperdono attorno alla media. Ne avremo bisogno più volte, e in particolare per capire la distribuzione di Poisson.

Durante la lettura incontrerai tre tipi di pause:

- le **soste di verifica**, con la risposta nascosta: prova a rispondere da solo e poi apri la soluzione;
- le **domande in apertura** di alcune sezioni: servono a mettere alla prova le tue intuizioni *prima* del calcolo, e non importa se all'inizio sbagli;
- i **riquadri «Che cosa abbiamo ottenuto»**, che riassumono in poche righe il punto raggiunto.

Non occorre memorizzare i dati storici né i valori decimali degli esempi: contano il ragionamento e la capacità di rifarlo.

La mappa è questa; ogni tappa si appoggia alla precedente.

Tappa	Domanda guida	Strumento che ne esce
La varianza	Due variabili con la stessa media possono comportarsi in modo diverso? Come lo misuriamo?	Varianza e deviazione standard
Atto I	Un numero che non esce da molto tempo diventa «più dovuto»?	Il problema, e un primo modello per una singola estrazione
Atto II	Quante prove servono per il primo successo?	Distribuzione **Geometrica**, assenza di memoria
Atto III	Come si distribuiscono i conteggi di eventi rari nei dati reali?	Il caso dei calci di cavallo
Atto IV	Quale modello produce quei conteggi?	Distribuzione di **Poisson**
Atto V	Come usiamo questi modelli nei sistemi informatici?	Capacità di un server, retry, limiti del modello

Il percorso principale comprende la sezione iniziale sulla varianza e gli Atti I–V.

Che cosa devi saper fare all'esame

Alla fine della settimana devi saper:

- spiegare il significato della **varianza**, scriverne la definizione come media degli scarti al quadrato e calcolarla su una semplice distribuzione discreta;
- riconoscere il modello **Geometrico**, dichiararne le ipotesi e la convenzione di conteggio, ricavare e usare PMF e coda, calcolare la media $1/p$ e interpretarla;
- spiegare e ricostruire la proprietà di **assenza di memoria**, distinguendo un'attesa futura da una sequenza osservata fin dall'inizio;
- spiegare l'idea dei **pezzetti di tempo** che porta dalla distribuzione binomiale alla distribuzione di Poisson, compreso il conto per zero eventi;
- usare la **PMF della distribuzione di Poisson**, sapere che $\mathbb{E}[X] = \mathrm{Var}(X) = \lambda$ e scegliere il parametro relativo all'intervallo della domanda;
- scegliere il modello in un'applicazione semplice e discutere le ipotesi, soprattutto indipendenza e stabilità del tasso.

Che cosa è facoltativo

Sono facoltativi e non richiesti all'esame:

- il filtro di Bloom (Lettura A);
- la derivazione completa del limite binomiale e dei momenti della distribuzione di Poisson (Lettura B);
- l'identità del secondo momento e le derivazioni delle varianze delle distribuzioni di Bernoulli e binomiale (Lettura C).

Una precisazione importante: la **proprietà** $\mathrm{Var}(X) = \lambda$ per la distribuzione di Poisson è richiesta; è la sua *dimostrazione* a essere facoltativa. L'esercizio sul campionamento senza reinserimento richiama un approfondimento facoltativo della Settimana 4.

Per codice, widget e fonti valgono le indicazioni generali per lo studio. I laboratori servono a mettere alla prova le previsioni: una simulazione ci fa *vedere* che una proprietà vale, mentre la spiegazione matematica ci dice *perché* vale. Le due cose si completano.

Prima di cominciare: che cosa sappiamo già

Useremo gli esiti e le probabilità della Settimana 1, insieme alle variabili aleatorie e al valore atteso della Settimana 4. Riprendiamoli attraverso un esempio che ritroveremo nello studio delle attese.

Che cos'è un modello probabilistico

Supponiamo di voler descrivere una richiesta inviata a un server. Consideriamo due esiti: la richiesta riesce oppure fallisce. Assegniamo probabilità $0{,}2$ al successo e $0{,}8$ al fallimento. Abbiamo costruito un primo **modello probabilistico**: una rappresentazione matematica di una situazione incerta, nella quale specifichiamo **gli esiti possibili, gli eventi e le loro probabilità**.

Nella Settimana 1, §5 abbiamo chiamato la struttura matematica di base *spazio di probabilità*, $(\Omega, \mathcal{F}, P)$. Per usarla come modello di un fenomeno reale, dobbiamo anche dire come gli esiti matematici rappresentano ciò che osserviamo e quali

ipotesi facciamo. Qui, per esempio, stiamo riassumendo tutti i possibili problemi della richiesta in un solo esito, «fallimento»; il valore $0{,}2$ è una scelta del modello, da giustificare nell'applicazione.

Ora immaginiamo di riprovare dopo un fallimento. Avere descritto una richiesta non basta a descrivere l'intera sequenza: dobbiamo aggiungere ipotesi sui rapporti fra i tentativi. Possiamo assumere che siano **indipendenti** e che la probabilità di successo resti **sempre** $0{,}2$. Sono ipotesi che ci permetteranno di fare i calcoli, e che dovremo confrontare con il funzionamento del servizio.

Solo a questo punto scegliamo che cosa misurare: per esempio, chiamiamo X il numero di tentativi fino al primo successo. La **distribuzione di** X dice quali valori può assumere questo numero e con quali probabilità. La ricaveremo dalle ipotesi appena dichiarate. Dunque il modello comprende la descrizione della situazione e dei legami fra i tentativi; la distribuzione di X descrive la particolare grandezza che abbiamo scelto di osservare.

Variabili aleatorie e valore atteso

Nella Settimana 4 abbiamo imparato a leggere l'esito di un esperimento attraverso una **variabile aleatoria**. Se ci interessa il numero di richieste fallite, la variabile X restituisce quel numero; la **distribuzione** descrive quali valori X può assumere e con quali probabilità.

Per una variabile discreta, la distribuzione si scrive con la **PMF** (*probability mass function*, funzione di massa di probabilità):

$$p_X(x) = P(X = x).$$

A sinistra c'è il nome della funzione, che prende un valore x; a destra c'è la probabilità che la variabile X assuma proprio quel valore. I valori della PMF sono **pesi**: ciascuno è non negativo e la loro somma è 1.

La media pesata dei risultati, dove i pesi sono le probabilità, è il **valore atteso**:

$$\mathbb{E}[X] = \sum_{x} x\, p_X(x).$$

La lettera x percorre tutti i valori possibili di X. In ciascun termine moltiplichiamo un valore per la probabilità di osservarlo, poi sommiamo tutti i contributi.

Un esempio minimo: un dado equo. I valori sono $1, 2, \dots, 6$, ciascuno con peso $1/6$, quindi

$$\mathbb{E}[X] = \frac{1}{6}(1 + 2 + 3 + 4 + 5 + 6) = \frac{21}{6} = 3{,}5.$$

Nessun lancio produce 3,5: il valore atteso è un **centro di massa** della distribuzione, e non deve essere un risultato che l'esperimento può dare. È il punto in cui, immaginando i pesi come masse sistemate sull'asse, la distribuzione starebbe in equilibrio.

Dal numero di tentativi possiamo passare ad altre grandezze, per esempio al tempo impiegato. Quando la trasformazione è lineare, anche il valore atteso si trasforma nello stesso modo: è la proprietà di **linearità**. Se una durata è $T = aX + b$, allora

$$\mathbb{E}[T] = a\,\mathbb{E}[X] + b.$$

Per esempio, se ogni tentativo dura 0,3 secondi e X conta i tentativi, la durata è $T = 0{,}3X$ e la sua media è $0{,}3\,\mathbb{E}[X]$. In più, se un conteggio è una somma di indicatrici, la sua media è la somma delle probabilità degli eventi contati. Questa proprietà è notevole perché **non richiede indipendenza**: vale anche quando le variabili sono legate fra loro.

Infine conosciamo la **distribuzione binomiale**. Fissiamo n prove indipendenti, ognuna con la stessa probabilità di successo p, e contiamo i successi. La media del conteggio è np.

In questo caso la domanda è:

> ***«Quanti successi in un numero fissato di prove?»***

Nota che qui il numero di prove è *deciso in anticipo*, mentre il numero di successi è ciò che *osserviamo*. In questa settimana cambieremo proprio ciò che è fissato e ciò che è osservato. Se fissiamo il numero di successi (uno solo) e osserviamo il numero di prove, otterremo la Geometrica. Se fissiamo un intervallo di tempo e osserviamo quanti eventi vi cadono, otterremo la distribuzione di Poisson.

Il passaggio da una distribuzione all'altra nasce dunque da una scelta: *che cosa teniamo fermo e che cosa contiamo*. Ci torneremo spesso.

Prima di proseguire — Stessa media, dispersione diversa: la varianza

Cominciamo da una domanda semplice. La media riassume una distribuzione con un solo numero: è sufficiente? Per vedere che non lo è, bastano due piccole storie.

Due pagamenti con lo stesso centro

Ripartiamo da dove ci eravamo fermati nella Settimana 4. Con Christiaan Huygens abbiamo dato un prezzo a una possibilità di guadagno: una moneta onesta decide il pagamento, 10 euro se esce testa e 0 euro se esce croce. Il **valore equo** di questo biglietto è il pagamento medio:

$$0 \cdot \frac{1}{2} + 10 \cdot \frac{1}{2} = 5 \text{ euro}.$$

Ora immagina che qualcuno ti offra una scelta:

- **A**: 5 euro in mano, subito;
- **B**: il biglietto di Huygens, cioè 10 euro con testa e 0 euro con croce.

Quale sceglieresti? Prova a rispondere prima di proseguire.

Per il criterio di Huygens le due offerte valgono lo stesso: 5 euro ciascuna. Eppure, messe davanti a questa scelta, le persone non sono indifferenti. Molte prendono i 5 euro sicuri; altre preferiscono tentare la sorte. Nessuna delle due scelte è un errore di calcolo: è una preferenza personale, e la probabilità non la impone. Lo avevamo già notato nella Settimana 4: chi teme di perdere denaro può preferire una somma certa.

Fermiamoci su questo fatto. Se due offerte con lo stesso valore equo non sono indifferenti, devono differire in qualcosa che il valore equo non vede. Che cosa? Per scoprirlo, trattiamo le due offerte come due variabili aleatorie: A vale sempre 5 euro; B vale 0 oppure 10 euro, con probabilità $1/2$ ciascuno.

Pagamento	Valori e probabilità	Valore atteso
Certo, A	5 con probabilità 1	5 euro
Incerto, B	0 e 10, ciascuno con probabilità $1/2$	$0 \cdot \frac{1}{2} + 10 \cdot \frac{1}{2} = 5$ euro

Il centro è lo stesso. Eppure i pagamenti si comportano in modo molto diverso: A coincide sempre con la propria media; B se ne allontana sempre di 5 euro, ora in su e ora in giù. **La media, da sola, non descrive questa differenza.** Ci serve un secondo numero, che dica *quanto ci si allontana dal centro*.

Dagli scarti alla varianza

Per costruire questo numero cominciamo dall'idea più naturale: guardare quanto ogni risultato dista dalla media. Indichiamo la media con la lettera greca μ, letta «mu»:

$$\mu = \mathbb{E}[X].$$

Se osserviamo il valore x, il suo **scarto dalla media** è $x - \mu$. Nel pagamento B gli scarti sono

$$0 - 5 = -5 \qquad \text{e} \qquad 10 - 5 = 5.$$

Il segno ci dice da che parte del centro ci troviamo: negativo sotto, positivo sopra. Il valore assoluto ci dice la distanza.

La mossa più semplice sarebbe fare la media degli scarti. Proviamo, per B:

$$(-5) \cdot \frac{1}{2} + 5 \cdot \frac{1}{2} = 0.$$

Otteniamo zero. E zero otterremmo anche per il pagamento certo, che non si disperde affatto. Gli scarti positivi e negativi **si cancellano**, e nascondono la differenza che volevamo descrivere.

Non è un caso fortuito del nostro esempio. Succede sempre, quando la media è finita. Per linearità:

$$\mathbb{E}[X - \mu] = \mathbb{E}[X] - \mu = \mu - \mu = 0.$$

La media degli scarti è dunque *sempre* zero: come misura di dispersione è inutile. Dobbiamo trovare un modo per impedire che i segni si compensino.

Ci sono due modi comuni per eliminare il segno: prendere il valore assoluto, oppure elevare al quadrato. Scegliamo il **quadrato**. Sia -5 sia 5 diventano 25, quindi niente si cancella. Il quadrato ha anche due vantaggi:

- attribuisce un peso maggiore agli scarti grandi: raddoppiare la distanza quadruplica il suo contributo;
- si presta bene al calcolo algebrico, come vedremo nella Lettura C. Il valore assoluto, invece, rende i conti molto più scomodi.

Facciamo ora la media degli scarti al quadrato. Questa quantità è la **varianza**:

$$\boxed{\mathrm{Var}(X) = \mathbb{E}[(X-\mu)^2] = \sum_x (x-\mu)^2 p_X(x).}$$

Osserviamo che la varianza è a sua volta un valore atteso: quello della quantità $(X-\mu)^2$, che è una funzione di X. Per calcolarlo si pesa ogni valore *trasformato* con la PMF di X, secondo la regola che abbiamo visto nella Settimana 4.

Per calcolare la varianza seguiamo quindi quattro passaggi:

1. trova la media μ;
2. sottraila a ogni valore possibile, ottenendo gli scarti;
3. eleva al quadrato ciascuno scarto;
4. pesa i quadrati con le probabilità e somma.

Un errore frequente da evitare subito: eleviamo al quadrato **gli scarti**, non le probabilità.

Applichiamo la procedura al pagamento B. La tabella mette in colonna i quattro passaggi:

Valore x	Probabilità $p_B(x)$	Scarto $x-5$	Quadrato $(x-5)^2$	Contributo pesato
0	$1/2$	-5	25	$25/2$
10	$1/2$	5	25	$25/2$

Sommando l'ultima colonna troviamo:

$$\mathrm{Var}(B) = \frac{25}{2} + \frac{25}{2} = 25.$$

Per A, invece, ogni scarto è $5-5=0$, quindi $\mathrm{Var}(A)=0$. La varianza distingue finalmente i due pagamenti, pur lasciando uguale la media. Era proprio ciò che cercavamo.

Due proprietà si leggono direttamente dalla definizione.

La varianza non è mai negativa. È una media di quantità non negative: ogni quadrato è maggiore o uguale a zero, e i pesi sono non negativi.

Vale zero soltanto quando non c'è dispersione. La varianza è nulla se e solo se X coincide con la propria media con probabilità 1. Su una distribuzione finita il motivo è semplice: basta che un solo valore di probabilità positiva sia diverso dalla media perché il suo contributo sia strettamente positivo, e nessun altro contributo può compensarlo.

Le unità di misura: la deviazione standard

Il quadrato cambia anche l'unità di misura. Se X è in euro, gli scarti sono in euro e i loro quadrati in *euro al quadrato*. Il 25 appena trovato non è un pagamento di 25 euro: ha un'unità di misura diversa da quella della variabile. Per tornare alle unità di partenza prendiamo la radice quadrata:

$$\sigma_X = \sqrt{\mathrm{Var}(X)}.$$

Questa è la **deviazione standard**; la lettera σ si legge «sigma». Per B vale $\sqrt{25} = 5$ euro.

In questo esempio ogni pagamento dista proprio 5 euro dalla media, quindi la deviazione standard coincide con la distanza tipica. In generale non è così: la deviazione standard misura una *scala* della dispersione, e non coincide necessariamente con la media delle distanze. Quando le distanze sono tutte diverse, i valori più lontani contano di più, per via del quadrato.

Finora le probabilità erano uguali. Vediamo che cosa succede quando non lo sono. Sia W una variabile che vale 0 con probabilità $0{,}9$ e 10 con probabilità $0{,}1$.

- La media è $\mu = 0 \cdot 0{,}9 + 10 \cdot 0{,}1 = 1$.
- Gli scarti sono $0 - 1 = -1$ e $10 - 1 = 9$.
- I quadrati sono 1 e 81.

Pesiamo con le probabilità:

$$\operatorname{Var}(W) = 1 \cdot 0{,}9 + 81 \cdot 0{,}1 = 0{,}9 + 8{,}1 = 9, \qquad \sigma_W = 3.$$

Guarda il peso dei due contributi: il valore raro, che capita una volta su dieci, genera quasi tutta la varianza (8,1 su 9). Questo accade perché il suo scarto è grande e il quadrato lo amplifica. È un fatto da ricordare: **gli eventi rari ma grandi possono dominare la dispersione**.

Sosta di verifica

Una variabile Y vale 1 oppure 3, con probabilità $1/2$ ciascuno. Calcola media e varianza prima di aprire la risposta.

Risposta

La media è $1 \cdot \frac{1}{2} + 3 \cdot \frac{1}{2} = 2$. Gli scarti sono -1 e 1, perciò la varianza è $1 \cdot \frac{1}{2} + 1 \cdot \frac{1}{2} = 1$.

Il valore atteso 2 non viene mai osservato, ma resta il centro rispetto al quale misuriamo gli scarti.

Sosta di verifica

Per un dado equo, la media è 3,5. Calcola la varianza con la definizione.

Risposta

Gli scarti dei sei valori sono $-2{,}5;\ -1{,}5;\ -0{,}5;\ 0{,}5;\ 1{,}5;\ 2{,}5$, e i loro quadrati sono $6{,}25;\ 2{,}25;\ 0{,}25;\ 0{,}25;\ 2{,}25;\ 6{,}25$. La somma è $17{,}5$. Con peso $1/6$ ciascuno:

$$\operatorname{Var} = \frac{17{,}5}{6} = \frac{35}{12} \approx 2{,}92, \qquad \sigma \approx 1{,}71.$$

La deviazione standard è circa 1,7: un lancio tipico dista un paio di punti dal 3,5.

Sosta di verifica

Tre variabili assumono i valori da 1 a 5 con queste probabilità:

Valore	1	2	3	4	5
X_1	0,2	0,2	0,2	0,2	0,2
X_2	0,1	0,2	0,4	0,2	0,1
X_3	0	0,2	0,6	0,2	0

Senza fare conti, perché hanno tutte media 3? Ordinale a occhio dalla più dispersa alla meno dispersa, poi controlla calcolando le tre varianze.

Risposta

Le tre distribuzioni sono simmetriche attorno a 3: ogni valore sotto il 3 ha un compagno alla stessa distanza sopra, con lo stesso peso. Il baricentro è quindi 3 per tutte e tre.

Gli scarti dei valori da 1 a 5 sono $-2, -1, 0, 1, 2$ e i loro quadrati $4, 1, 0, 1, 4$, uguali per le tre variabili. Cambiano soltanto i pesi:

$$\begin{aligned}\operatorname{Var}(X_1) &= 0{,}2\,(4+1+0+1+4) = 2,\\ \operatorname{Var}(X_2) &= 4\cdot 0{,}1 + 1\cdot 0{,}2 + 0 + 1\cdot 0{,}2 + 4\cdot 0{,}1 = 1{,}2,\\ \operatorname{Var}(X_3) &= 1\cdot 0{,}2 + 1\cdot 0{,}2 = 0{,}4.\end{aligned}$$

Le deviazioni standard sono circa 1,41, 1,10 e 0,63. Più massa lontano dal centro significa più varianza: X_1 mette peso 0,4 sugli estremi 1 e 5, X_3 nessuno.

Che cosa abbiamo ottenuto

La media dice *dove* sta il centro; la varianza dice *quanto ci si allontana* da esso. La si calcola con gli scarti al quadrato, perché gli scarti con segno si cancellano. La sua radice, la deviazione standard, ha le stesse unità della variabile.

Per il percorso principale basta questo metodo, cioè la definizione. Nella Lettura C ricaveremo una formula alternativa e la applicheremo alla distribuzione binomiale.

Una avvertenza per le variabili con infiniti valori possibili: una media finita non assicura una varianza finita. Occorre controllare anche la convergenza della somma degli scarti al quadrato. Per le distribuzioni di questa settimana tutto va bene, ma non è automatico in generale.

Atto I — Il 53 che non usciva

Nel gioco del Lotto, ogni settimana si estraggono numeri su più «ruote», che sono come urne separate. Il caso più celebre è quello del **53 di Venezia**: nel periodo 2003–2005 il 53 rimase assente dalla ruota di Venezia per **182 estrazioni consecutive**. Molti giocatori puntarono su quel numero con una convinzione crescente: dopo tanta attesa, *doveva* uscire.

Fermiamoci un momento e facciamo una previsione, prima di qualunque calcolo. Il 53 è assente da 100 estrazioni. Alla prossima:

- è **più probabile** del solito che esca?
- è **meno probabile**?
- ha **la stessa probabilità** di sempre?

Annota la tua risposta, e magari anche quanto ne sei sicuro. Alla fine dell'Atto II torneremo qui. Non serve sapere nulla dei dettagli delle puntate: serve capire che cosa il modello ci dice sulle estrazioni *future*.

Per studiare questa attesa consideriamo una ruota fissata, per esempio Venezia, e descriviamo come avvengono le estrazioni.

- A ogni estrazione vengono scelti **5 numeri distinti fra 1 e 90**.
- All'interno della stessa estrazione i numeri sono scelti **senza reinserimento**: un numero estratto non rientra nell'urna.
- Tra un'estrazione e la successiva si riparte con tutti i 90 numeri.
- I sorteggi successivi sono **indipendenti** ed equi.

L'ultima ipotesi è il cuore del modello: l'urna non «ricorda» che cosa è uscito prima.

Queste ipotesi permettono di calcolare la probabilità che il 53 compaia in una singola estrazione.

Primo ragionamento (per simmetria). Fra i 90 numeri non ce n'è uno privilegiato. Se immaginiamo di disporre i 90 numeri in un ordine casuale e di prendere i primi 5, ciascun numero ha la stessa probabilità di trovarsi fra i primi 5. Il 53 viene estratto se occupa una delle prime 5 posizioni su 90, quindi:

$$p = P(\text{esce il } 53) = \frac{5}{90} = \frac{1}{18}.$$

Secondo ragionamento (conto diretto). Le cinquine possibili sono $\binom{90}{5}$. Quelle che contengono il 53 sono tante quante i modi di scegliere gli altri quattro numeri fra gli 89 rimasti, cioè $\binom{89}{4}$. Il rapporto dà

$$\frac{\binom{89}{4}}{\binom{90}{5}} = \frac{5}{90} = \frac{1}{18},$$

perché $\binom{90}{5} = \frac{90}{5}\binom{89}{4}$. I due ragionamenti concordano, come devono.

La probabilità che il 53 **non** esca è il complementare:

$$1 - p = 1 - \frac{1}{18} = \frac{17}{18}.$$

Attenzione a che cosa stiamo calcolando: non la probabilità di ottenere una particolare cinquina, ma soltanto la probabilità che **un numero fissato** compaia fra i cinque estratti. Sono domande diverse, con risposte molto diverse.

Ora cambiamo prospettiva. Scegliamo il punto da cui cominciare a osservare e *contiamo le estrazioni fino alla prima comparsa del 53*. Questo numero non è fissato in anticipo: potrebbe bastare una sola estrazione, potrebbero servirne cento.

Qui nasce la novità. Nella distribuzione binomiale decidevamo il numero di prove e contavamo i successi. Adesso decidiamo che cosa vogliamo ottenere (un successo) e contiamo **quante prove servono**.

Se abbiamo già osservato 100 assenze, conosciamo una parte di questa attesa. Per sapere quanto resta da aspettare dovremo tener conto di quell'informazione, attraverso la probabilità condizionata.

Atto II — Aspettare il primo successo: la Geometrica

1. Prima decidiamo che cosa contiamo

Per studiare un'attesa di questo tipo partiamo da una moneta. La lanciamo finché esce la prima testa e chiamiamo X il **numero totale di lanci effettuati, compreso quello riuscito**. Le prime sequenze possibili mostrano come funziona il conteggio:

Inizio della sequenza	Valore di X	Perché
Testa	1	La prima prova riesce
Croce, testa	2	Un fallimento, poi il successo
Croce, croce, testa	3	Due fallimenti, poi il successo

Le prove successive al primo successo non interessano: l'esperimento si ferma lì.

La costruzione generale richiede tre ingredienti:

1. prove con **due esiti**, chiamati successo e fallimento;
2. la **stessa probabilità di successo** p a ogni prova;
3. **indipendenza** fra tutte le prove.

Supponiamo prima $0 < p < 1$. La parola «successo» identifica semplicemente l'esito che stiamo aspettando: non esprime un giudizio sul suo valore. Per esempio, in un controllo di qualità il «successo» potrebbe essere trovare un pezzo difettoso.

Con queste ipotesi, X ha distribuzione **Geometrica di parametro** p:

$$X \sim \text{Geometrica}(p).$$

Il simbolo $\sim$ si legge «ha distribuzione». I valori possibili sono $1, 2, 3, \ldots$: non c'è un massimo, ma li possiamo elencare uno dopo l'altro. Una variabile con infiniti valori elencabili è ancora **discreta**.

Confrontiamo la costruzione con quella della distribuzione binomiale, per fissare bene la differenza:

	Che cosa è fissato in anticipo	Che cosa osserviamo
Distribuzione binomiale	il numero di prove n	il numero di successi
Geometrica	il traguardo: **un** successo	il numero di prove necessarie

Una convenzione da tenere ben presente: qui contiamo **tutte** le prove, compresa quella riuscita. Per questo X **parte da 1**.

I casi limite si trattano a parte. Se $p = 1$, la prima prova riesce certamente: $X = 1$ con probabilità 1. Se $p = 0$, il successo non arriva mai, e non otteniamo una Geometrica finita con questa convenzione.

2. La PMF: tradurre un valore in una storia

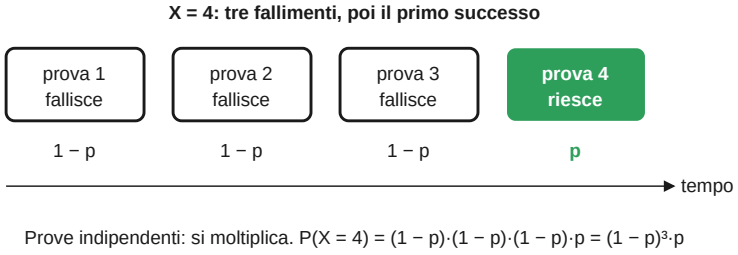
Per assegnare una probabilità ai valori di X dobbiamo capire quali esiti delle singole prove li producono. Se il primo successo arriva alla seconda prova, per esempio, sappiamo anche che cosa è accaduto alla prima: deve essere fallita. Ogni valore di X determina così una precisa sequenza. Consideriamo i primi tre casi.

$X = 1$. La prima prova riesce: la storia è «S». Probabilità p.

$X = 2$. La prima prova fallisce, la seconda riesce: la storia è «F, S». Per indipendenza moltiplichiamo: $(1 - p) \cdot p$.

$X = 3$. Due fallimenti e poi il successo: «F, F, S». Probabilità $(1 - p)(1 - p)p = (1 - p)^2 p$.

Chiediamo ora $P(X = 4)$. Per avere il primo successo alla quarta prova devono accadere, nell'ordine, tre fallimenti e un successo. Se la seconda prova riuscisse, ci saremmo già fermati: non sarebbe più $X = 4$. L'ordine non è libero.



Il valore X = 4 corrisponde a una sola storia: tre fallimenti seguiti da un successo.

Ciascun fallimento ha probabilità $1 - p$; il successo ha probabilità p. **L'indipendenza** ci permette di moltiplicare:

$$P(X = 4) = (1 - p) \cdot (1 - p) \cdot (1 - p) \cdot p = (1 - p)^3 p.$$

Con una moneta onesta, $p = 1/2$, quindi $P(X = 4) = (1/2)^4 = 1/16$. Nota che **non compare un coefficiente binomiale**. Nella distribuzione binomiale dovevamo scegliere *quali* prove fossero riuscite; qui l'unica storia compatibile con $X = 4$ ha il successo in ultima posizione, e tutte le posizioni precedenti sono già determinate.

Lo schema è chiaro: per avere $X = k$ servono esattamente $k - 1$ fallimenti prima dell'unico successo finale. Abbiamo così costruito la PMF:

$$\boxed{P(X = k) = (1 - p)^{k-1} p, \qquad k = 1, 2, 3, \ldots}$$

L'esponente di $(1 - p)$ è il numero di fallimenti *prima* del successo; il fattore p finale è il successo che chiude la storia.

> **La convenzione fa parte del modello**
>
> Se un libro o una libreria conta soltanto i fallimenti prima del successo, usa invece $Y = X - 1$, che parte da 0. Per avere $Y = j$ servono j fallimenti e poi un successo: quindi $P(Y = j) = (1 - p)^j p$ per $j = 0, 1, \ldots$. In un esercizio, prima di usare una formula, controlla che cosa conta la variabile. Questa dispensa conta sempre anche la prova riuscita.

Applichiamo la formula con $p = 0{,}2$ e guardiamo i primi valori:

k	Storia richiesta	Probabilità
1	Successo	$0{,}2$
2	Fallimento, successo	$0{,}8 \cdot 0{,}2 = 0{,}16$
3	Due fallimenti, successo	$0{,}8^2 \cdot 0{,}2 = 0{,}128$
4	Tre fallimenti, successo	$0{,}8^3 \cdot 0{,}2 = 0{,}1024$

Osserva come procede la colonna: ogni passo moltiplica il peso precedente per $1 - p = 0{,}8$, un numero minore di 1. I pesi decrescono quindi di continuo, e la barra più alta è la prima.

Questo merita una riflessione. Il primo tentativo è **il singolo valore più probabile**, anche quando p è piccolo. Ma non concludere troppo in fretta che «il successo arriva di solito subito»: le molte altre possibilità, considerate *insieme*, possono avere un peso complessivo molto maggiore. Con $p = 0{,}2$, per esempio, $P(X = 1) = 0{,}2$ ma $P(X > 1) = 0{,}8$.

3. La coda: superare una soglia

Sapere la probabilità di un singolo valore non risponde ancora a una domanda come «basteranno tre tentativi?». Per rispondere dobbiamo considerare insieme tutte le attese che superano quella soglia: è la **coda** della distribuzione. Cerchiamo quindi la probabilità che **non bastino le prime tre prove**.

L'evento è $X > 3$. Si verifica se e solo se le prime tre prove falliscono. Notiamo bene che *non imponiamo* un successo alla quarta: potrebbe arrivare alla quarta, alla quinta o molto dopo, e a noi va bene qualunque di questi casi. Quindi:

$$P(X > 3) = (1 - p)^3.$$

In generale, per un intero $k \geq 0$:

$$\boxed{P(X > k) = (1 - p)^k.}$$

Superare la soglia k significa fallire le prime k prove; di che cosa succede dopo non ci occupiamo.

Con $p = 0{,}2$ otteniamo $P(X > 3) = 0{,}8^3 = 0{,}512$. Confrontiamolo con $P(X = 4) = 0{,}1024$ della tabella: il primo evento *include* tutti i possibili successi dopo la terza prova (alla quarta, alla quinta, e così via), il secondo ne specifica uno solo. È per questo che le due probabilità sono diverse: la seconda è la prima moltiplicata per p, perché, dopo tre fallimenti, chiediamo anche che la quarta prova riesca.

Usando il complementare otteniamo la probabilità di riuscire **entro** k prove:

$$\boxed{P(X \leq k) = 1 - (1 - p)^k.}$$

Nel nostro esempio con $k = 3$ vale $1 - 0{,}512 = 0{,}488$. Possiamo ritrovarla sommando i primi tre pesi della tabella, come controllo: $0{,}2 + 0{,}16 + 0{,}128 = 0{,}488$. I due conti concordano.

Approfondimento facoltativo — La stessa formula sommando la PMF, per ogni k

Il controllo appena fatto suggerisce una seconda strada. L'evento «riuscire entro k prove» è l'unione degli eventi disgiunti $\{X=1\}, \{X=2\}, \dots, \{X=k\}$, quindi possiamo sommare i pesi della PMF invece di ragionare sui fallimenti. Mostriamo che le due strade danno **sempre** lo stesso risultato, per qualunque $k \geq 1$ e qualunque $0 < p \leq 1$.

Scriviamo $q = 1 - p$ per alleggerire la notazione. Per l'additività,

$$P(X \leq k) = \sum_{j=1}^{k} P(X = j) = \sum_{j=1}^{k} q^{\,j-1} p = p\left(1 + q + q^2 + \cdots + q^{k-1}\right).$$

Il fattore p è comune a tutti i termini e lo abbiamo raccolto. Resta da calcolare la somma tra parentesi, che chiamiamo S_k.

Per calcolare S_k moltiplichiamo per $1 - q$ e distribuiamo:

$$\begin{aligned}(1-q)\,S_k &= \left(1 + q + q^2 + \cdots + q^{k-1}\right) - \left(q + q^2 + \cdots + q^{k-1} + q^k\right) \\ &= 1 - q^k.\end{aligned}$$

Nella prima parentesi ci sono le potenze da q^0 a q^{k-1}; nella seconda, ottenuta moltiplicando per q, quelle da q^1 a q^k. Tutte le potenze intermedie compaiono una volta con il segno più e una volta con il segno meno, e si cancellano: restano solo il primo termine della prima parentesi e l'ultimo della seconda.

Attenzione: non abbiamo ancora trovato S_k. Abbiamo trovato quanto vale S_k **moltiplicato per** $1 - q$.

Per isolare S_k dividiamo **entrambi i lati** dell'uguaglianza per $1 - q$. Possiamo farlo perché $1 - q = p$ non è zero:

$$S_k = \frac{1 - q^k}{1 - q}.$$

Ora ricordiamo che $1 - q = p$ e riscriviamo soltanto il denominatore:

$$S_k = \frac{1 - q^k}{p}.$$

Quindi S_k non è $1 - q^k$: è $1 - q^k$ **diviso per** p. Con $p = 0{,}2$, $q = 0{,}8$ e $k = 3$: direttamente $S_3 = 1 + 0{,}8 + 0{,}64 = 2{,}44$, e con la formula $(1 - 0{,}512)/0{,}2 = 0{,}488/0{,}2 = 2{,}44$.

Torniamo a $P(X \leq k) = p \cdot S_k$ e sostituiamo il valore appena trovato. Il p davanti e il p al denominatore si semplificano:

$$P(X \leq k) = p \cdot S_k = p \cdot \frac{1 - q^k}{p} = 1 - q^k = 1 - (1-p)^k,$$

e, passando al complementare,

$$P(X > k) = 1 - P(X \leq k) = (1-p)^k.$$

È esattamente la formula trovata contando i fallimenti. Il fattore p davanti alla somma si semplifica con il denominatore: è il motivo per cui nel risultato finale compare soltanto la probabilità di fallire.

Con $p = 0{,}2$ e $k = 3$ abbiamo trovato $S_3 = 2{,}44$, quindi $P(X \le 3) = 0{,}2 \cdot 2{,}44 = 0{,}488$. La formula dà $1 - 0{,}8^3 = 1 - 0{,}512 = 0{,}488$.

Le due strade rispondono alla stessa domanda in modi diversi. Contare i fallimenti è più rapido, perché guarda solo le prime k prove. Sommare la PMF è più lungo, ma è un controllo indipendente: se le due strade non coincidessero, avremmo sbagliato la PMF o la lettura dell'evento. Infine, quando k cresce, $(1-p)^k$ tende a 0 e quindi $P(X \le k)$ tende a 1: i pesi della PMF sommano a 1, come vedremo tra poco.

Un'ultima attenzione alle parole, che sono una fonte frequente di errori. «Servono **più di** k prove» significa $X > k$. «Servono **almeno** k prove» significa $X \ge k$: in questo caso bastano $k-1$ fallimenti, perché la prova k può anche riuscire. Perciò:

$$P(X \ge k) = P(X > k-1) = (1-p)^{k-1}, \qquad k \ge 1.$$

Sosta di verifica

Con $p = 0{,}2$, calcola la probabilità che «servano più di 3 prove» e quella che «servano almeno 3 prove». Perché i due esponenti differiscono di uno?

Risposta

«Più di 3 prove» significa $X > 3$: servono 3 fallimenti, quindi $0{,}8^3 = 0{,}512$.

«Almeno 3 prove» significa $X \ge 3$: bastano 2 fallimenti, perché la terza prova può riuscire o no. La probabilità è $0{,}8^2 = 0{,}64$.

La differenza di un esponente è la differenza di un fallimento richiesto: nel primo caso la terza prova *deve* fallire, nel secondo è libera.

Ogni attesa finita può essere superata: nessuna soglia k è «garantita». Tuttavia, poiché $0 < 1-p < 1$, la quantità $(1-p)^k$ **tende a zero** quando k cresce. La probabilità di *non riuscire mai* è dunque zero. Diciamo che il successo arriva **con probabilità 1**. Attenzione: questo non fornisce un numero finito di prove entro cui il successo sia garantito. Dice soltanto che l'attesa infinita ha probabilità nulla.

Possiamo anche controllare direttamente che la PMF sommi a 1, senza calcolare una serie infinita. Gli eventi $X \le K$ e $X > K$ sono complementari, quindi:

$$\sum_{k=1}^{K} P(X = k) = 1 - (1-p)^K \;\longrightarrow\; 1.$$

Leggiamo: sommando i primi K pesi otteniamo tutto tranne la coda $(1-p)^K$. Aumentando K includiamo sempre più valori possibili e il peso ancora escluso tende a zero. In altre parole, la somma di tutti i pesi è 1: ecco la verifica che quella che abbiamo scritto è davvero una PMF.

4. La media: quante prove servono in media?

Se ogni prova riesce con probabilità $1/5$, ci aspettiamo che su molte prove circa una su cinque sia un successo. Questo suggerisce un'attesa media di cinque prove fra un successo e il successivo. Per $p = 1/2$ lo stesso ragionamento suggerisce due prove. L'intuizione porta quindi al reciproco di p.

Il risultato, dimostrato nel riquadro facoltativo qui sotto, è che il valore atteso della Geometrica vale

$$\boxed{\mathbb{E}[X] = \frac{1}{p}.}$$

Con una moneta onesta, 2 lanci. Per il 53 del Lotto, $1/(1/18) = 18$ estrazioni. Per un tentativo che riesce con probabilità $0{,}2$, la media è 5.

Approfondimento facoltativo — Perché la media è $1/p$

Questa dimostrazione non fa parte del programma. Serve a chi vuole vedere da dove viene il risultato: la facciamo prima guardando solo il primo tentativo, poi con la definizione di valore atteso.

1. Il ragionamento sul primo tentativo.

Chiamiamo $\mu = \mathbb{E}[X]$. Per il momento supponiamo che questa media sia finita; subito dopo verificheremo che lo è davvero. Alla prima prova ci sono due possibilità:

- con probabilità p riusciamo subito: abbiamo usato **una** prova, e l'attesa è finita;
- con probabilità $1 - p$ falliamo: abbiamo usato **una** prova e dobbiamo aspettare ancora. Chiamiamo X' il numero di prove *ancora necessarie* dopo il fallimento. Il totale è allora $1 + X'$.

Il secondo punto è quello che richiede più attenzione, e usa sia l'indipendenza sia la costanza di p: dopo un fallimento, il problema che resta ha *esattamente la stessa distribuzione* del problema iniziale, cioè X' si comporta come X. È come ricominciare da capo, con una prova già spesa in più. Poiché il valore atteso dipende soltanto dalla distribuzione, $\mathbb{E}[X'] = \mu$ e quindi, nel caso «ho fallito», la media del totale è $1 + \mu$.

Per combinare le due medie useremo la **legge della probabilità totale per il valore atteso**. Se $A_1, \dots, A_n$ sono eventi a due a due disgiunti, di probabilità positiva, la cui unione è tutto lo spazio (ad ogni esito se ne verifica esattamente uno), allora

$$\mathbb{E}[X] = \sum_{i=1}^{n} \mathbb{E}[X \mid A_i]\, P(A_i).$$

Qui $\mathbb{E}[X \mid A_i]$ è la media di X calcolata *solo* nel caso in cui A_i si verifica, cioè $\sum_k k\, P(X = k \mid A_i)$. La regola dice che la media totale è la media delle medie parziali, pesate con la probabilità di ciascun caso: come il voto medio di una classe, ottenuto dalle medie dei sottogruppi pesate con la loro numerosità. Segue dalla legge della probabilità totale $P(X = k) = \sum_i P(X = k \mid A_i) P(A_i)$: basta moltiplicare per k e sommare su k.

Nel nostro caso i due eventi sono «la prima prova riesce» e «la prima prova fallisce», con $\mathbb{E}[X \mid \text{riesce}] = 1$ e $\mathbb{E}[X \mid \text{fallisce}] = 1 + \mu$. Pesiamo dunque le due medie con le probabilità dei casi:

$$\mu = p \cdot 1 + (1 - p)(1 + \mu).$$

Con probabilità p il costo medio è 1; con probabilità $1 - p$ il costo medio è $1 + \mu$. La media totale tiene conto delle due possibilità con i rispettivi pesi.

Sviluppando la parentesi e raccogliendo i termini otteniamo:

$$\begin{aligned} \mu &= p + (1 - p) + (1 - p)\mu \\ &= 1 + (1 - p)\mu, \\ \mu - (1 - p)\mu &= 1, \\ p\mu &= 1. \end{aligned}$$

Nell'ultimo passaggio abbiamo portato a sinistra il termine con μ e raccolto: $\mu - (1 - p)\mu = \mu\,[1 - (1 - p)] = p\mu$. Poiché $p > 0$, possiamo dividere per p:

$$\mu = \frac{1}{p}.$$

2. Perché la media è davvero finita.

Il ragionamento precedente non basterebbe se μ fosse infinita: non potremmo sottrarre termini infiniti, e il ragionamento non starebbe in piedi. Controlliamo dunque la finitezza, usando le code che già conosciamo.

Un'attesa di quattro prove può essere contata come $4 = 1 + 1 + 1 + 1$: una prima unità sempre presente, una seconda se l'attesa supera 1, una terza se supera 2, una quarta se supera 3. Lo stesso ragionamento vale per ogni attesa intera positiva. Facendo la media di questi contributi, ciascuno non negativo, otteniamo:

$$\mathbb{E}[X] = P(X > 0) + P(X > 1) + P(X > 2) + \cdots.$$

La media di un'attesa è quindi la somma delle probabilità di superare ogni soglia: 0, poi 1, poi 2, e così via.

Per una Geometrica le code sono $1, (1-p), (1-p)^2, \ldots$. Poniamo $q = 1 - p$ per alleggerire la scrittura. La somma dei primi K termini è

$$S_K = 1 + q + q^2 + \cdots + q^{K-1}.$$

Moltiplicarla per q sposta tutti i termini di una posizione. Sottraendo le due espressioni, i termini intermedi si cancellano e restano soltanto il primo e l'ultimo:

$$S_K - qS_K = 1 - q^K, \qquad S_K = \frac{1 - q^K}{1 - q}.$$

Poiché $q^K \to 0$ e $1 - q = p > 0$, la somma tende a $1/p$, che è finito. La somma delle code conferma dunque *sia* la finitezza *sia* il valore della media, e questo secondo argomento non usa l'ipotesi che μ fosse finita. Il passaggio alle somme infinite è lecito perché tutti i contributi sono non negativi.

3. Lo stesso risultato dalla definizione di valore atteso.

Se preferisci partire dalla definizione, con $q = 1 - p$ e $P(X = k) = q^{k-1}p$ si ha

$$\mu = \sum_{k=1}^{\infty} k\, q^{k-1} p.$$

Il primo termine, $k = 1$, vale $1 \cdot p = p$: è il caso «riesco subito». Scriviamo a parte gli altri:

$$\mu = p + \sum_{k=2}^{\infty} k\, q^{k-1} p.$$

Nella somma poniamo $k = j + 1$, con $j \geq 1$. Estraiamo un fattore q e spezziamo $j + 1$ in j più 1:

$$\sum_{j=1}^{\infty}(j+1)\,q^{j}p = q\left[\sum_{j=1}^{\infty} j\,q^{j-1}p + \sum_{j=1}^{\infty} q^{j-1}p\right] = q\,(\mu+1).$$

La prima somma tra parentesi è, per definizione, μ. La seconda è la somma di tutti i pesi della PMF, quindi vale 1. Rimettendo insieme:

$$\mu = p + q\,(1+\mu).$$

È esattamente l'equazione del ragionamento sul primo tentativo, con $q = 1-p$. I due modi di procedere sono lo stesso conto: il termine $p \cdot 1$ raccoglie il caso $k=1$, il termine $(1-p)(1+\mu)$ raccoglie tutti i casi $k \geq 2$ in un colpo solo.

C'è un fraintendimento diffuso sulla media. Diciotto estrazioni in media **non** significa «entro diciotto estrazioni». Per il Lotto:

$$P(X > 18) = \left(\frac{17}{18}\right)^{18} \approx 0{,}357.$$

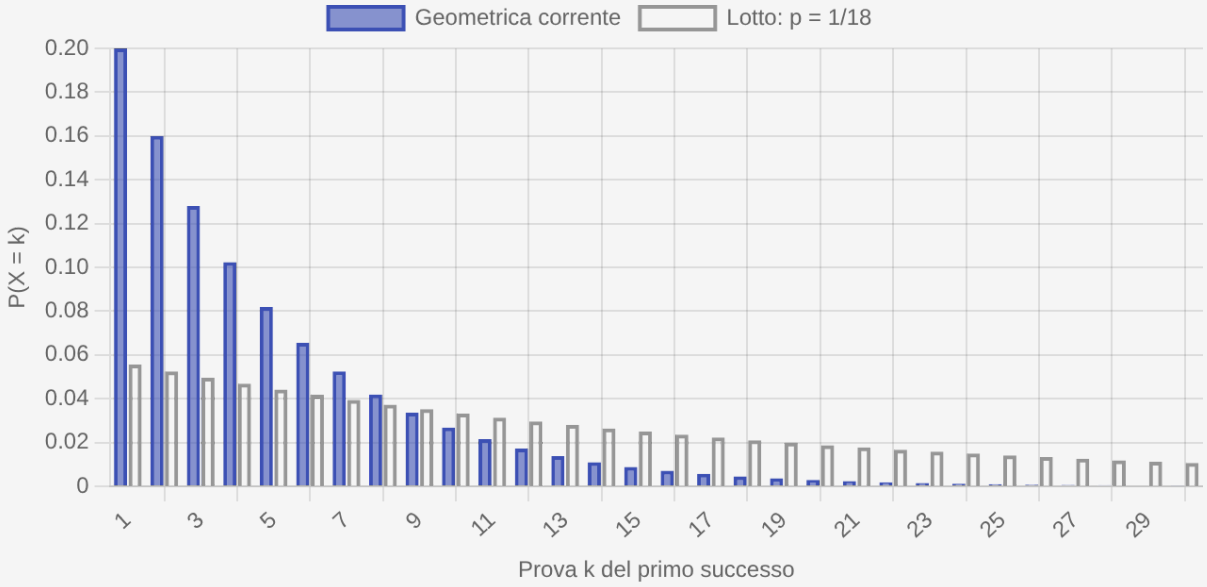
Più di un terzo delle attese supera la media. Visto dall'altro lato, quasi due attese su tre si chiudono entro 18 estrazioni, e metà già entro 13. Come può allora la media valere 18? La distribuzione ha una coda lunga a destra: le attese oltre 18 sono poco più di un terzo dei casi, ma da sole forniscono circa 12,9 dei 18 punti della media, oltre il 70%. Un'attesa di 60 estrazioni è rara, ma sposta la media quanto molte attese brevi messe insieme. È lo stesso fenomeno del secondo esempio della varianza: pochi valori lontani dal centro possono spostare molto un valore atteso.

Che cosa abbiamo ottenuto

La Geometrica conta le prove fino al primo successo. Ha PMF $(1-p)^{k-1}p$, coda $P(X>k) = (1-p)^k$ e media $1/p$. La PMF richiede un successo in una posizione precisa; la coda richiede soltanto dei fallimenti.

Esplora: la forma di un'attesa

Usa lo strumento con un'idea precisa in mente. Parti da $p = 0{,}2$: la media vale 5. Prima di spostare il cursore a $p = 0{,}5$, prevedi la nuova media e la probabilità di superare 10 prove; poi verifica. Infine avvicinati al riferimento del Lotto, $p = 1/18$: la coda si allunga e la media sale a 18. Il grafico mostra soltanto le prime 30 barre; i valori oltre il bordo conservano probabilità positiva.



La barra più alta è sempre la prima. La media 1/p cresce quando p diminuisce, e la coda si allunga.

E[X] = 1/p: **5.00** P(X > 10) = (1 − p)^10: **0.107**

5. L'assenza di memoria: quanto resta da aspettare?

Torniamo al 53 e supponiamo di aver osservato 100 assenze. Sappiamo dunque che $X > 100$: una parte della sequenza è ormai nota. Ci interessa la probabilità di *altre* 18 assenze, cioè che $X > 118$, **dato** ciò che sappiamo già. Per calcolarla dobbiamo restringere l'attenzione alle attese che hanno superato 100.

Ricordiamo la definizione di probabilità condizionata: la probabilità di A sapendo che si è verificato B è

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}.$$

Qui $A = \{X > 118\}$ e $B = \{X > 100\}$, quindi:

$$P(X > 118 \mid X > 100) = \frac{P(\{X > 118\} \cap \{X > 100\})}{P(X > 100)}.$$

L'intersezione si semplifica. Se il successo arriva dopo la prova 118, arriva certamente anche dopo la prova 100: l'evento $\{X > 118\}$ è *contenuto* in $\{X > 100\}$. Perciò l'intersezione coincide con $\{X > 118\}$ e il numeratore è $P(X > 118)$. Sostituiamo le code, che conosciamo:

$$\begin{aligned} P(X > 118 \mid X > 100) &= \frac{(17/18)^{118}}{(17/18)^{100}} \\ &= \left(\frac{17}{18}\right)^{118-100} \\ &= \left(\frac{17}{18}\right)^{18}. \end{aligned}$$

Nel secondo passaggio abbiamo usato la regola delle potenze: dividere potenze con la stessa base sottrae gli esponenti. Il risultato coincide con $P(X > 18)$, la probabilità di 18 assenze quando *iniziamo* a osservare. **I 100 fallimenti non hanno modificato la distribuzione dell'attesa futura.**

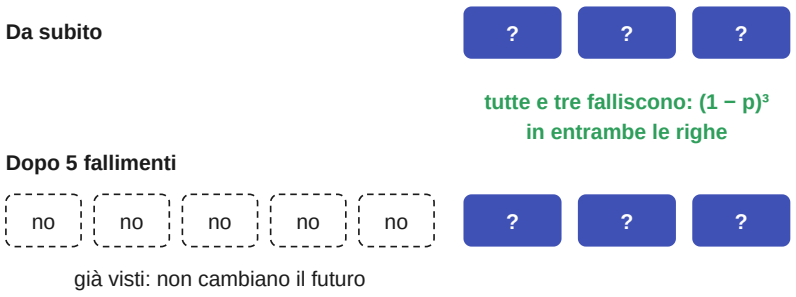
Il fatto non dipende dai numeri scelti. Generalizziamo con due interi $s, t \geq 0$ e $0 < p < 1$. Qui s è il tempo già trascorso e t è l'attesa ulteriore che ci interessa. L'evento condizionante ha probabilità $(1-p)^s > 0$, quindi possiamo dividere:

$$\begin{aligned} P(X > s + t \mid X > s) &= \frac{P(X > s + t)}{P(X > s)} \\ &= \frac{(1-p)^{s+t}}{(1-p)^s} \\ &= (1-p)^t = P(X > t). \end{aligned}$$

Abbiamo ottenuto l'**assenza di memoria**:

$$\boxed{P(X > s + t \mid X > s) = P(X > t).}$$

A sinistra abbiamo già aspettato s prove senza successo e guardiamo l'attesa *residua*. A destra partiamo da zero e guardiamo un'attesa *nuova*. Le due probabilità coincidono per ogni soglia futura t.



Le prove future sono le stesse, con le stesse probabilità, con o senza un passato di fallimenti.

Una precisazione per non fraintendere. L'«orologio del totale» continua a contare: i tentativi già spesi restano spesi, e il totale sarà comunque maggiore di s. È la **distribuzione del numero di prove ancora necessarie** a essere uguale a quella iniziale. Dopo 100 fallimenti al Lotto restano, in media, altre 18 prove: il totale medio, *condizionato* a quelle 100 assenze, è 118.

Il caso $p = 1$ richiede attenzione: dopo una prova non possiamo aver osservato un fallimento, quindi non ha senso condizionare su quell'evento impossibile.

Approfondimento facoltativo — Dall'assenza di memoria alla proprietà di Markov

L'assenza di memoria dice che il passato non conta: dopo s fallimenti, il futuro dell'attesa è lo stesso dell'inizio. Molti fenomeni non sono così semplici, ma soddisfano una versione più debole e molto più utile della stessa idea: il passato conta, ma **solo attraverso il presente**.

La proprietà di Markov. Immaginiamo un sistema che a ogni passo n si trova in uno *stato* X_n: il meteo di oggi, la casella di una pedina, la pagina web che stiamo guardando. Diciamo che il sistema è **markoviano** se, per prevedere il passo successivo, basta conoscere lo stato attuale:

$$P(X_{n+1} = j \mid X_n = i,\, X_{n-1}, \ldots, X_0) = P(X_{n+1} = j \mid X_n = i).$$

Il resto della storia si può dimenticare: ciò che serve del passato è già contenuto nello stato presente. Le prove ripetute della Geometrica sono un caso estremo. Finché aspettiamo, lo stato è sempre lo stesso, «non è ancora successo», e quindi il futuro non dipende nemmeno da quanto abbiamo già aspettato.

Un esempio. Un modello giocattolo del meteo: se oggi piove, domani pioverà con probabilità $0{,}6$; se oggi è sereno, con probabilità $0{,}2$. Il modello non chiede se ha piovuto anche ieri. È una semplificazione, ed è proprio questo il punto: con due soli numeri possiamo calcolare la probabilità di qualunque sequenza di giorni, moltiplicando una probabilità condizionata dopo l'altra, come negli alberi della Settimana 2. Se oggi piove, la probabilità che piova anche domani e dopodomani è $0{,}6 \cdot 0{,}6 = 0{,}36$.

Perché è così importante. Andrej Markov introdusse queste *catene* nel 1906; è lo stesso Markov della disuguaglianza della Settimana 8. L'idea si è diffusa ovunque perché trasforma un problema con una memoria lunghissima in uno in cui basta guardare un passo alla volta. Due esempi:

- **Simulazione.** I metodi *Monte Carlo a catena di Markov* (MCMC) costruiscono apposta una catena che, camminando a lungo, produce campioni da distribuzioni troppo complicate per essere calcolate direttamente.
- **Web.** Il PageRank di Google immagina un navigatore che salta a caso da un link all'altro. L'importanza di una pagina è la frazione di tempo che il navigatore, alla lunga, vi trascorre.

E nell'intelligenza artificiale.

- **Modelli del linguaggio.** Un modello linguistico genera un token alla volta, e la scelta del prossimo dipende solo dal contesto che ha davanti. Con una finestra di contesto finita è, formalmente, una catena di Markov il cui stato è l'intero contesto. Shannon, nel 1948, faceva lo stesso con uno stato di una sola parola.
- **Apprendimento per rinforzo.** Un agente che gioca o guida un robot si modella con un *processo decisionale di Markov*: stato attuale e azione scelta determinano le probabilità dello stato successivo.
- **Modelli di diffusione.** I generatori di immagini imparano a percorrere all'indietro una catena di Markov che aggiunge rumore passo dopo passo: partono da puro rumore e la risalgono fino a un'immagine nuova.

La lezione per chi costruisce modelli. La proprietà di Markov dipende da come **scegliamo lo stato**. Se il meteo di domani dipende da oggi e da ieri, basta prendere come stato la coppia (ieri, oggi); il prezzo è uno stato più grande. Se invece lo stato trascura qualcosa che conta, come un guasto persistente nei retry della §8, il modello sbaglia.

Approfondimento facoltativo — Il legame con la media $1/p$

Se hai letto l'approfondimento facoltativo della §4 sulla media, riconoscerai l'idea. Il ragionamento sul primo tentativo, «dopo un fallimento il problema ricomincia identico», era già un'applicazione dell'assenza di memoria. Qui la rendiamo esplicita e la formuliamo come proprietà della distribuzione.

Sosta di verifica

Con $p = 1/18$, qual è la probabilità di altre 18 assenze dopo 30 assenze già osservate? E dopo 500? Prova a rispondere senza fare nessuna divisione.

Risposta

In entrambi i casi vale $(17/18)^{18} \approx 0{,}357$. L'assenza di memoria dice che la probabilità non dipende dal passato s, che sia 30 o 500.

6. Il ritardatario e la fallacia del giocatore

La probabilità che il 53 esca alla prossima estrazione rimane $1/18$, anche dopo 100 assenze. Né più alta, né più bassa. Credere che sia diventato «dovuto» è la **fallacia del giocatore**.

L'intuizione sbagliata nasce da un'idea ragionevole in apparenza: «alla lunga le frequenze si compensano». È vero che, su moltissime estrazioni, la frequenza del 53 si avvicina a $1/18$. Ma non si avvicina perché l'urna «recupera» il ritardo. Il ritardo non viene recuperato: viene **diluito**. Dopo 100 assenze, le prossime 1000 estrazioni produrranno ancora circa $1000/18$ comparse, come se nulla fosse successo; le 100 assenze iniziali pesano sempre meno nella frequenza complessiva, ma non vengono compensate.

Per vedere l'errore, confrontiamo due domande simili che hanno risposte molto diverse:

Informazione disponibile	Domanda	Probabilità
Non abbiamo ancora osservato la sequenza	Mancherà per tutte le prossime 118 estrazioni?	$(17/18)^{118} \approx 0{,}00118$
Abbiamo già osservato 100 assenze	Mancherà per altre 18 estrazioni?	$(17/18)^{18} \approx 0{,}357$

Nella prima domanda tutte le 118 assenze sono ancora incerte, e la loro congiunzione è molto rara. Nella seconda le prime 100 sono già note: la probabilità condizionata riguarda soltanto ciò che resta da osservare. La rarità dell'*intera* sequenza non rende meno probabili i suoi possibili proseguimenti. Una sequenza di 118 assenze è rara *prima* di cominciare; dopo le prime 100, quella rarità è già stata «spesa».

Finora ci siamo chiesti che cosa succede **dopo** un ritardo. Resta un'altra domanda, che spiega perché i ritardi vistosi ci colpiscono tanto: **quanto deve stupirci** un ritardo così lungo? La risposta dipende da come lo abbiamo trovato.

- **Scelgo prima.** Oggi decido di seguire il 53 sulla ruota di Venezia, da questa estrazione in avanti. La probabilità che manchi per 100 estrazioni di fila è $(17/18)^{100} \approx 0{,}0033$, circa 1 su 300. Se succede, è davvero sorprendente.
- **Cerco dopo.** Apro le statistiche del Lotto e cerco il numero più in ritardo. Sto guardando 90 numeri su una decina di ruote, cioè circa 900 coppie (numero, ruota). Ciascuna ha la stessa probabilità $(17/18)^{100} \approx 0{,}0033$ di avere alle

spalle almeno 100 assenze, quindi in media ne troverò $900 \cdot 0{,}0033 \approx 3$.

L'evento è lo stesso, «un numero assente da 100 estrazioni», ma nel secondo caso abbiamo avuto centinaia di occasioni per vederlo. In questo caso, trovarne uno è normale; strano sarebbe non trovarne nessuno. Anche il 53 di Venezia non era stato scelto in anticipo: è diventato famoso proprio perché, fra tutti, era il più in ritardo. È come cercare la persona più alta in uno stadio: che superi i due metri non ci stupisce, perché l'abbiamo scelta proprio per la sua altezza.

Questo è un secondo errore, diverso dalla fallacia del giocatore, e spesso la alimenta:

Errore	Che cosa pensiamo	Perché è sbagliato
Di previsione	«È in ritardo, quindi uscirà»	La probabilità resta $1/18$
Di valutazione	«Un ritardo così è incredibile, deve voler dire qualcosa»	L'abbiamo trovato cercando fra centinaia di candidati

La regola generale è che, prima di giudicare sorprendente un risultato, bisogna dichiarare **quante possibilità abbiamo esaminato**. In statistica si parla di problema dei **confronti multipli**.

Approfondimento facoltativo — E se le attese non sono indipendenti?

Sulla stessa ruota escono 5 numeri senza reinserimento: se esce il 53, resta un posto in meno per gli altri. Le attese di numeri diversi quindi non sono del tutto indipendenti. Il conto della media però non ne risente. Il numero di coppie in ritardo è una somma di 900 indicatrici, e la media di una somma è la somma delle medie anche per variabili dipendenti.

La dipendenza cambia invece la probabilità di trovarne *almeno una*. Vediamolo con i numeri: una coppia fissata ha probabilità $q = (17/18)^{100} \approx 0{,}003293$ di avere almeno 100 assenze. Se i ritardi dei 90 numeri di una ruota fossero indipendenti, la probabilità che nessuno abbia quel ritardo sarebbe $(1-q)^{90}$; quella di trovarne almeno uno sarebbe quindi $1-(1-q)^{90} \approx 25{,}69\%$. Tenendo conto della dipendenza, si ottiene invece circa $25{,}90\%$. Il calcolo usa l'inclusione-esclusione: sommiamo le probabilità dei singoli ritardi, sottraiamo quelle dei ritardi simultanei di due numeri, aggiungiamo quelle dei ritardi simultanei di tre, e così via, per evitare conteggi multipli.

Su 10 ruote indipendenti tra loro, la probabilità di trovarne almeno uno diventa $1-(1-0{,}258987)^{10} \approx 95{,}01\%$. La dipendenza modifica il valore preciso, ma resta il punto: cercando fra più numeri e più ruote, abbiamo più occasioni di incontrare un ritardo estremo.

Da portare con sé

Il modello Geometrico descrive prove nuove, indipendenti, con la stessa p. L'assenza di memoria deriva direttamente da queste ipotesi. Un passato di fallimenti non crea un credito da riscuotere: l'urna non sa nulla.

7. Laboratorio: osservare molte attese

Una simulazione permette di osservare come le proprietà appena ricavate si riflettono in un insieme di attese: possiamo confrontare la media e le frequenze del campione con le previsioni teoriche.

Prima di eseguire il codice, scrivi tre previsioni per $p = 1/18$:

1. la media dell'attesa;
2. la probabilità di superare 18 prove;

3. la probabilità di altre 18 assenze dopo averne già osservate 30.

Le ultime due, per l'assenza di memoria, dovrebbero coincidere.

Il codice genera 50.000 attese complete. `generatore.random()` produce un numero uniforme fra 0 e 1: confrontarlo con p realizza una prova con probabilità di successo p. Ogni ciclo del `while` conta una nuova prova, fino al primo successo.

```
from random import Random

generatore = Random(42)
p = 1 / 18          # il 53 è uno dei 5 numeri estratti su 90
prove = 50000       # quante attese complete simuliamo


def attesa(p):
    """Numero dell'estrazione in cui arriva il primo successo."""
    k = 1
    # Ogni estrazione è nuova: la probabilità non dipende dal passato.
    while generatore.random() >= p:
        k += 1
    return k


attese = [attesa(p) for _ in range(prove)]
print(f"Media teorica 1/p: {1 / p:.2f}")
print(f"Media simulata: {sum(attese) / prove:.2f}")

# Coda: più di 18 estrazioni significa 18 fallimenti di fila.
oltre_18 = sum(x > 18 for x in attese) / prove
print(f"P(X > 18) teorica: {(1 - p) ** 18:.4f}")
print(f"P(X > 18) simulata: {oltre_18:.4f}")

# Assenza di memoria: guardiamo solo le attese già oltre 30.
lunghe = [x for x in attese if x > 30]
ancora = sum(x > 30 + 18 for x in lunghe) / len(lunghe)
print(f"Attese già oltre 30: {len(lunghe)}")
print(f"Tra queste, ancora 18 fallimenti: {ancora:.4f}")
```

Un punto da leggere con attenzione: il denominatore dell'ultima frazione è `len(lunghe)`. Stiamo guardando soltanto le attese che hanno già superato 30. Dividere per tutte le 50.000 attese risponderebbe a un'altra domanda, la probabilità *non condizionata* di superare 48.

La media simulata sarà vicina a 18 e le due frequenze vicine a 0,357. Non devono coincidere esattamente con la teoria: una simulazione finita fluttua sempre un po'.

Un esperimento in più. Prova a sostituire la soglia 30 con 60 in entrambe le righe interessate. Il gruppo condizionante si restringe, quindi la stima diventa più variabile. Se un esperimento producesse un gruppo vuoto, quella frequenza non sarebbe calcolabile: questo non significherebbe che la probabilità teorica è zero, ma soltanto che non abbiamo osservato abbastanza casi.

8. Tentativi, timeout e limite ai retry

Un client invia una richiesta e, se fallisce, riprova. Per progettare questa procedura ci interessano sia il numero di tentativi necessari sia il tempo che richiedono.

Supponiamo che ogni tentativo riesca con probabilità $p = 0{,}2$, indipendentemente dagli altri. Il numero X di tentativi fino al primo successo è Geometrico e ha media 5.

Se **ogni tentativo dura esattamente 0,3 secondi**, il tempo totale è $T = 0{,}3X$. Per linearità:

$$\mathbb{E}[T] = 0{,}3\,\mathbb{E}[X] = 0{,}3 \cdot 5 = 1{,}5 \text{ secondi.}$$

L'ipotesi sulla durata conta. Se inseriamo pause crescenti, oppure se i tentativi riusciti e quelli falliti hanno durate diverse, il tempo totale deve includere quelle durate e il conto cambia.

Una durata media di 1,5 secondi non dice ancora quando convenga interrompere i tentativi. Per scegliere un limite serve stabilire quale probabilità di insuccesso siamo disposti ad accettare. Se vogliamo una probabilità di successo **almeno del 99% entro r tentativi**, traduciamo la richiesta in una disuguaglianza sulla funzione cumulativa:

$$P(X \le r) \ge 0{,}99 \quad \Longleftrightarrow \quad 1 - 0{,}8^{r} \ge 0{,}99 \quad \Longleftrightarrow \quad 0{,}8^{r} \le 0{,}01.$$

Cerchiamo il più piccolo intero r che soddisfa l'ultima condizione. Proviamo qualche valore:

r	5	10	20	21
$0{,}8^{r}$	0,328	0,107	0,0115	0,0092

La soglia 0,01 viene superata verso il basso proprio fra 20 e 21: $0{,}8^{20} \approx 0{,}0115 > 0{,}01$, mentre $0{,}8^{21} \approx 0{,}00922 < 0{,}01$. Servono quindi **21 tentativi**. Cinque è la media dell'attesa senza limite; ventuno è un limite che lascia meno dell'1% di probabilità di non riuscire. Sono due domande diverse, con due risposte molto diverse.

Un client che si ferma dopo r prove non esegue più il numero illimitato X: esegue $\min(X, r)$ prove e può terminare senza successo. La Geometrica ci aiuta comunque, perché la probabilità di esaurire il budget è proprio la coda $P(X > r) = 0{,}8^{r}$.

Controlliamo infine l'ipotesi più delicata. Durante un guasto persistente, sapere che un tentativo è fallito può rendere più probabile un altro fallimento. In quel caso le prove non sono indipendenti, e il modello Geometrico non descrive più la situazione.

Quando una richiesta fallisce, il client può riprovare: questo nuovo tentativo si chiama *retry*. Riprovare subito, però, può servire a poco: se il server è ancora sovraccarico, anche la nuova richiesta rischia di fallire e aggiunge altro lavoro da smaltire.

Una possibile strategia è aspettare sempre di più fra un tentativo e il successivo. Per esempio: dopo il primo fallimento aspettiamo 1 secondo, dopo il secondo 2 secondi, poi 4, poi 8. Poiché la pausa raddoppia ogni volta, questa strategia si chiama *exponential backoff*. Le pause danno al servizio tempo per riprendersi e riducono la frequenza delle richieste.

Questo aiuta a gestire il guasto, ma basta per poter usare la Geometrica? Dobbiamo ancora controllare le sue due ipotesi: **tentativi indipendenti** e **stessa probabilità di successo p a ogni tentativo**. Se il guasto persiste, gli esiti possono restare legati tra loro; se nel frattempo il servizio si riprende, la probabilità di successo può cambiare. Allungare le pause, da solo, non garantisce nessuna delle due ipotesi. La Geometrica può descrivere il **numero di tentativi fino al primo successo** soltanto se queste ipotesi sono ragionevoli; il tempo totale di attesa dipende anche dalle pause scelte.

Che cosa abbiamo ottenuto

La Geometrica ci permette di rispondere a due domande diverse: quanti tentativi servono in media ($1/p$) e quanti tentativi concedere per raggiungere almeno una probabilità di successo prefissata (usando la coda). La seconda domanda è essenziale quando progettiamo i retry, per esempio nella consegna di messaggi: permette di scegliere il limite ai tentativi in funzione dell'affidabilità richiesta, sotto le ipotesi del modello.

Atto III — I calci di cavallo dell'esercito prussiano

9. Prima del modello: che cosa misura la tabella?

Finora fissavamo il traguardo del primo successo e contavamo le prove necessarie per raggiungerlo. Nei dati che stiamo per leggere è fissato invece il periodo di osservazione, un anno, e contiamo **quanti eventi vi accadono**. Il caso dei militari morti per il calcio di un cavallo ci permetterà di studiare questa diversa domanda a partire da una tabella storica.

La distribuzione che useremo per descrivere questi conteggi nasce però sessant'anni prima della loro analisi, e lontano dalle caserme: in uno studio sui giudizi dei tribunali.

Nel 1837 il matematico francese **Siméon-Denis Poisson** pubblicò un libro dal titolo lungo: *Recherches sur la probabilité des jugements en matière criminelle et en matière civile*, cioè «Ricerche sulla probabilità dei giudizi in materia penale e civile». La domanda che lo muoveva era concreta: quanto è probabile che una giuria sbagli, condannando un innocente o assolvendo un colpevole?

Dentro il libro, in poche pagine, Poisson studia un caso particolare della distribuzione binomiale: **moltissime prove, ciascuna con una probabilità di successo piccolissima**. In questo caso il conto esatto della distribuzione binomiale è scomodo, e Poisson ne ricava una formula più semplice, che dipende da un solo numero: la media np. È la formula che oggi porta il suo nome. Nel libro, però, resta un risultato di calcolo, un passaggio tecnico: non viene confrontata con conteggi osservati. Come accade spesso nella storia della scienza, l'idea non era del tutto nuova: Abraham de Moivre aveva ottenuto un'approssimazione simile già nel 1711.

Poisson è ricordato anche per un nome. Negli stessi anni chiamò **legge dei grandi numeri** un'idea che studieremo nella Settimana 8: se ripetiamo una prova moltissime volte, la frequenza di un evento si stabilizza vicino alla sua probabilità. Ne abbiamo già visto un esempio nell'Atto II: su moltissime estrazioni la frequenza del 53 si avvicina a $1/18$, senza che l'urna «recuperi» nulla.

Sessantuno anni dopo, nel 1898, l'economista e statistico Ladislaus von Bortkiewicz pubblicò *Das Gesetz der kleinen Zahlen*, «La legge dei piccoli numeri». Il titolo richiama la legge di Poisson. I «grandi numeri» sono le moltissime ripetizioni che rendono stabili le frequenze. I «piccoli numeri» sono i conteggi piccoli degli eventi rari: zero, uno, due incidenti in un anno. Anche questi conteggi, raccolti su molte unità, mostrano una regolarità, e nel libro Bortkiewicz li confronta proprio con la formula di Poisson.

Il quarto esempio del libro riguarda i militari dell'esercito prussiano morti per il calcio di un cavallo. È un caso particolarmente istruttivo, perché ci permette di confrontare una distribuzione teorica con dati registrati molto prima del nostro calcolo.

Seguiremo la stessa strada, ma in un ordine diverso da quello della storia. Prima guardiamo i dati, senza formule (§9 e §10). Poi costruiamo noi la formula di Poisson, un passo alla volta (Atto IV). Infine la mettiamo alla prova sulla tabella di Bortkiewicz (§14), come fece lui.

Il libro considera 20 anni, dal 1875 al 1894, e 14 corpi d'armata. Qui usiamo la tabella relativa ai **10 corpi comparabili** del confronto principale. Il punto metodologico è scegliere unità con esposizioni al rischio abbastanza simili: mescolare unità molto diverse (per esempio un corpo con molti più cavalli degli altri) può cambiare la dispersione dei conteggi.

L'unità osservata è un **corpo-anno**: un corpo d'armata seguito per un anno. Le osservazioni sono quindi $10 \cdot 20 = 200$. Per ciascuna registriamo un conteggio, cioè il numero di morti di quel corpo in quell'anno:

Morti in un corpo-anno	**0**	**1**	**2**	**3**	**4**	**5 o più**
Numero di corpi-anno	109	65	22	3	1	0

Leggiamo una colonna con attenzione. Il 22 sotto il 2 significa che **22 corpi-anno hanno avuto due morti ciascuno**. Non significa che i morti totali siano 22. La riga in basso conta *corpi-anno*; la riga in alto indica *quanti morti* ciascuno di essi ha avuto. Confondere le due righe è l'errore più comune con le tabelle di frequenza.

Prima di fare qualunque calcolo, controlliamo che le frequenze sommino a 200:

$$109 + 65 + 22 + 3 + 1 = 200.$$

Il controllo torna: ogni corpo-anno compare esattamente in una colonna.

Per trovare il numero **totale** di morti, moltiplichiamo invece ogni conteggio per la sua frequenza (22 corpi-anno con 2 morti ciascuno danno $2 \cdot 22 = 44$ morti, e così via):

$$0 \cdot 109 + 1 \cdot 65 + 2 \cdot 22 + 3 \cdot 3 + 4 \cdot 1 = 65 + 44 + 9 + 4 = 122.$$

Dividendo il totale dei morti per il numero di osservazioni otteniamo la media:

$$\overline{x} = \frac{122}{200} = 0{,}61 \text{ morti per corpo-anno.}$$

Nessun corpo-anno ha avuto 0,61 morti: ogni dato è un intero. La media riassume le 200 osservazioni ed è un numero di sintesi, non un risultato possibile.

Nota bene: Il simbolo $\overline{x}$ indica la media di questi dati; $\mathbb{E}[X]$ indica invece la media teorica di una distribuzione. Nelle settimane successive chiariremo il legame fra questi due numeri. Per ora ci limitiamo ad usare il valore 0,61 per costruire il modello probabilistico e confrontarne le probabilità con la tabella.

10. Possiamo prevedere la forma del conteggio?

La media 0,61 riassume il numero di morti per corpo-anno, ma da sola non dice come quel totale si distribuisca fra le unità osservate. La tabella mostra anche molti zeri e pochi conteggi superiori a due. Vorremmo spiegare questa forma attraverso il meccanismo degli incidenti: **esiste un modello che, usando soltanto la media 0,61, produca probabilità credibili per zero, uno, due e più morti?**

Pensiamo alle *occasioni* di incidente: molte persone, molti giorni, molti contatti con i cavalli. Ogni singola occasione ha una probabilità piccolissima di produrre l'evento contato, ma le occasioni sono moltissime. È proprio la situazione in cui la

distribuzione binomiale ci dà un primo schema: tante prove, ciascuna con probabilità p molto piccola.

Qui però incontriamo un ostacolo pratico. Non conosciamo un numero preciso di prove n, né una probabilità p per occasione. Una giornata potrebbe contenere un numero diverso di contatti con i cavalli. Il dato disponibile suggerisce piuttosto il valore del prodotto np, cioè il **numero medio di eventi** nell'unità osservata, che qui è 0,61.

La *distribuzione di Poisson* nasce da un'idealizzazione: lasciamo crescere il numero di occasioni, facciamo diminuire la probabilità di ciascuna, e **teniamo fissata la media totale**. Nel limite non ci serve più sapere né n né p: ci basta la media. Questo è il motivo per cui la distribuzione di Poisson è così utile nella pratica.

La rarità, da sola, non assicura però che questo modello sia adatto. Contano anche l'**indipendenza** delle occasioni e l'**uniformità** dell'esposizione: sono le ipotesi che dovremo rendere precise nella costruzione.

Prima di costruire la formula, torna alla media 0,61. Essa è inferiore a 1: ti aspetti molti corpi-anno senza morti? Quale frazione dei 200 prevedi con zero morti: circa la metà, oppure quasi tutti? Annota la tua stima, la confronteremo con il conto del §12.

Atto IV — Costruire la distribuzione di Poisson

11. Dividere l'intervallo in pezzetti

Fissiamo un corpo e un anno. Chiamiamo λ, «lambda», il **numero medio di eventi nell'intero intervallo**. Per il modello dei dati scegliamo $\lambda = 0{,}61$: è una *media* riferita all'intervallo scelto (qui un anno), e non una probabilità.

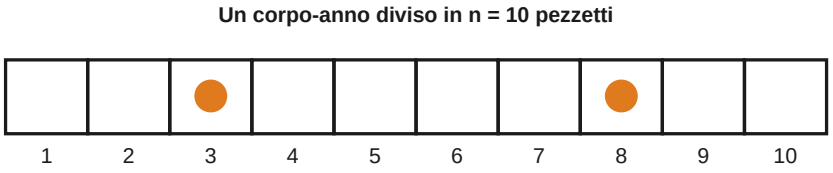
Partiamo da una semplificazione: consideriamo l'anno come un unico pezzetto e ammettiamo soltanto l'assenza di eventi oppure un evento. Il conteggio vale quindi 0 oppure 1, ed è una variabile bernoulliana. La media di una variabile bernoulliana è la sua probabilità, e deve valere λ: dunque $p = \lambda = 0{,}61$. La probabilità di zero eventi è $1 - 0{,}61 = 0{,}39$.

Questo primo modello esclude però conteggi che compaiono nella tabella: un anno può contenere due o tre morti. Dividendo l'anno in due metà e ammettendo un evento in ciascuna potremmo già arrivare a un totale di due. Suddivisioni più fini permetterebbero conteggi ancora maggiori, mantenendo semplice la descrizione di ciascun pezzetto.

Dividiamo l'anno in n pezzetti uguali. In un primo modello semplificato ciascun pezzetto può contenere un evento oppure nessuno. Se vogliamo che la media totale resti λ, la probabilità di un evento in ciascun pezzetto deve essere

$$p_n = \frac{\lambda}{n}, \qquad \text{perché} \qquad n p_n = n\frac{\lambda}{n} = \lambda.$$

Il pedice n ricorda che la probabilità cambia quando cambia la suddivisione. Con più pezzetti, ciascuno dura meno e la sua probabilità diminuisce. Un punto da fissare bene: **non stiamo aumentando la durata totale dell'osservazione**, ma soltanto tagliandola in parti più fini. Quando n cresce, la media totale rimane λ.



Più pezzetti significa pezzetti più corti, ciascuno con un evento ancora più raro; la media totale resta la stessa.

Assumiamo che i pezzetti abbiano la stessa probabilità di evento e siano indipendenti. Il conteggio del modello a n pezzetti, che chiamiamo X_n, segue allora una distribuzione binomiale:

$$X_n \sim \text{Binomiale}\left(n, \frac{\lambda}{n}\right), \qquad n > \lambda.$$

La condizione $n > \lambda$ assicura che $\lambda/n < 1$, cioè che λ/n sia davvero una probabilità. Con $\lambda = 0{,}61$ basta già $n = 1$.

La restrizione a un solo evento per pezzetto rende questo un **modello approssimato**: nella realtà un intervallo finito può contenere più eventi. L'idea è di rendere i pezzetti sempre più corti, così che la probabilità di eventi multipli nello stesso pezzetto diventi trascurabile nel conteggio complessivo.

Questo funziona soltanto sotto un'ipotesi sul fenomeno: gli eventi non devono arrivare in **gruppi simultanei** che restano indivisibili, per quanto accorciamo il pezzetto. Dividere il tempo, da solo, non crea indipendenza né elimina le raffiche. Stiamo costruendo un modello per eventi che:

- arrivano **singolarmente**;
- con un **tasso stabile**;
- e con **conteggi indipendenti** in intervalli che non si sovrappongono.

Teniamo a mente questa lista: ci tornerà utile quando discuteremo i limiti del modello.

12. Zero eventi: il primo limite

Il conteggio totale è zero soltanto se tutti gli n pezzetti sono vuoti. Questo caso permette di seguire il passaggio a suddivisioni sempre più fini senza dover scegliere le posizioni degli eventi. La probabilità di un pezzetto vuoto è $1 - \lambda/n$; per indipendenza moltiplichiamo n volte lo stesso fattore:

$$P(X_n = 0) = \left(1 - \frac{\lambda}{n}\right)^n.$$

Con $\lambda = 0{,}61$ calcoliamo questa probabilità per suddivisioni sempre più fini.

Sosta di verifica

Un corpo-anno è diviso in n pezzetti; in ciascuno capita un morto con probabilità $0{,}61/n$, indipendentemente dagli altri. Con la calcolatrice, trova la probabilità di nessun morto in un anno per $n = 1$, 2, 10, 100 e 365. Che cosa succede ai valori quando n cresce?

Risposta

Si calcola $(1 - 0{,}61/n)^n$ per ciascun n; per confronto aggiungiamo anche $n = 1000$:

Pezzetti n	1	2	10	100	365	1000
Probabilità di zero eventi in un anno	0,3900	0,4830	0,5329	0,5423	0,5431	0,5432

Per esempio, con $n = 2$: $(1 - 0{,}305)^2 = 0{,}695^2 \approx 0{,}4830$. Un errore comune è calcolare $(1 - 0{,}61)^n$: così ogni pezzetto avrebbe probabilità 0,61, e il numero medio di morti crescerebbe con n invece di restare 0,61.

Il primo valore della tabella è quello che avevamo trovato prima, con un solo pezzetto: $1 - 0{,}61 = 0{,}39$. Poi i valori crescono sempre più lentamente e **sembrano stabilizzarsi** attorno a 0,543. Questo è il comportamento che ci interessa spiegare.

Nell'espressione cambiano *due cose insieme*: il numero di fattori n aumenta, e ciascun fattore $1 - \lambda/n$ si avvicina a 1. Se guardiamo soltanto la base potremmo essere tentati di dire che il risultato sia 1, perché $1^n = 1$. Ma la base non è esattamente 1: è un po' più piccola, e questo scarto viene elevato a una potenza sempre più grande.

Le due variazioni si bilanciano e producono un limite diverso da 1. Un modo per intuire quale sia: per x piccolo vale $\ln(1 - x) \approx -x$, quindi

$$\ln\left(1 - \frac{\lambda}{n}\right)^n = n \ln\left(1 - \frac{\lambda}{n}\right) \approx n \cdot \left(-\frac{\lambda}{n}\right) = -\lambda.$$

Il logaritmo del risultato si avvicina a $-\lambda$, e il risultato stesso a $e^{-\lambda}$. Questo è un argomento di *intuizione*; il risultato preciso è un teorema di analisi matematica.

$$\boxed{\left(1 - \frac{\lambda}{n}\right)^n \longrightarrow e^{-\lambda}.}$$

La freccia significa che i valori si avvicinano al numero a destra quando n cresce senza limite, mantenendo λ fissato. Il numero $e \approx 2{,}71828$ è la base dell'esponenziale naturale; un esponente negativo indica il reciproco, quindi $e^{-\lambda} = 1/e^{\lambda}$.

Un chiarimento sul ruolo della tabella: qui usiamo questo risultato dell'analisi per capire il modello, ma non lo stiamo dimostrando attraverso i numeri. La tabella mostra, in un caso, il comportamento che il teorema garantisce in generale.

Applicando il limite al nostro corpo-anno, con $\lambda = 0{,}61$, otteniamo:

$$P(X=0) = e^{-0{,}61} \approx 0{,}54335.$$

Fermiamoci a distinguere due cose che si confondono facilmente. Il parametro $\lambda = 0{,}61$ **non è una probabilità**: è una *media*, un numero di eventi. Il valore $0{,}54335$ è invece la probabilità di un conteggio preciso, zero.

Su 200 corpi-anno il numero atteso di unità con zero morti è la probabilità moltiplicata per 200:

$$200 \cdot e^{-0{,}61} \approx 108{,}67.$$

Ne osserviamo 109. Abbiamo trovato la prima colonna della tabella usando **soltanto la media**. E guarda la tua previsione di prima: la frazione di corpi-anno senza morti è circa 54%, poco più della metà.

13. Da zero eventi alla PMF completa

Per avere esattamente un evento dobbiamo lasciare vuoti tutti i pezzetti tranne uno. Rispetto al caso di zero eventi compare quindi una scelta: *quale* dei n pezzetti contiene l'evento? Le possibilità sono n e sono incompatibili fra loro, perciò sommiamo le loro probabilità. Ciascuna richiede un evento nel pezzetto scelto e zero eventi negli altri $n-1$:

$$\begin{aligned} P(X_n = 1) &= n \cdot \frac{\lambda}{n}\left(1 - \frac{\lambda}{n}\right)^{n-1} \\ &= \lambda\left(1 - \frac{\lambda}{n}\right)^{n-1}. \end{aligned}$$

Il fattore n si semplifica con il denominatore di λ/n. Per trovare il limite, riscriviamo la potenza come

$$\left(1 - \frac{\lambda}{n}\right)^{n-1} = \frac{(1-\lambda/n)^{n}}{1-\lambda/n}.$$

Il numeratore tende a $e^{-\lambda}$ per il limite del §12; il denominatore tende a 1. Quindi

$$P(X_n = 1) \longrightarrow \lambda e^{-\lambda}.$$

Per k eventi scegliamo k pezzetti pieni. Il numero delle scelte è $\binom{n}{k}$, mentre una configurazione fissata ha probabilità $(\lambda/n)^k(1-\lambda/n)^{n-k}$. Passando al limite per k **fissato** e $n \to \infty$ si ottiene la distribuzione di **Poisson**:

$$\boxed{P(X=k) = \frac{\lambda^k e^{-\lambda}}{k!}, \qquad k = 0, 1, 2, \ldots, \quad \lambda > 0.}$$

Scriviamo $X \sim \text{Poisson}(\lambda)$. Il conto completo del limite è nella Lettura B: qui impariamo a leggere e usare il risultato, che è ciò che serve all'esame.

Nella formula compaiono due numeri che hanno ruoli molto diversi:

- k è il **conteggio di cui chiediamo la probabilità**: quanti eventi vogliamo vedere;

- λ è il **numero medio di eventi nell'intervallo fissato**: è il parametro del modello.

Non devono coincidere. Con $\lambda = 0{,}61$ possiamo chiedere $P(X = 3)$; con $\lambda = 3$ possiamo chiedere $P(X = 0)$. Prima di calcolare, chiediti sempre quale dei due numeri hai davanti.

Il fattoriale $k!$ è il prodotto degli interi da 1 a k, con la convenzione $0! = 1$. Scriviamo i primi casi:

$$
\begin{aligned}
P(X = 0) &= \frac{\lambda^0 e^{-\lambda}}{0!} = e^{-\lambda}, \\
P(X = 1) &= \lambda e^{-\lambda}, \\
P(X = 2) &= \frac{\lambda^2 e^{-\lambda}}{2}, \\
P(X = 3) &= \frac{\lambda^3 e^{-\lambda}}{6}.
\end{aligned}
$$

Con $\lambda = 0{,}61$ e $e^{-0{,}61} \approx 0{,}54335$ avremmo ad esempio $P(X = 2) = \frac{0{,}61^2}{2} \cdot 0{,}54335 = \frac{0{,}3721}{2} \cdot 0{,}54335 \approx 0{,}10109$.

La distribuzione di Poisson ammette zero eventi e **non ha un massimo**: il modello attribuisce probabilità positiva a ogni intero non negativo. La distribuzione binomiale con n prove, invece, non può superare n. La distribuzione di Poisson può approssimare bene la distribuzione binomiale nel regime di eventi rari, ma le due distribuzioni non sono identiche per un n finito.

Se dobbiamo costruire una tabella, possiamo evitare di ricalcolare ogni volta potenze e fattoriali. Per $k \geq 1$ facciamo il rapporto fra due pesi consecutivi:

$$
\frac{P(X = k)}{P(X = k - 1)} = \frac{\lambda^k e^{-\lambda}}{k!} \cdot \frac{(k-1)!}{\lambda^{k-1} e^{-\lambda}} = \frac{\lambda}{k}.
$$

Vediamo perché. Il fattore esponenziale $e^{-\lambda}$ compare sopra e sotto e si cancella; il rapporto delle potenze $\lambda^k / \lambda^{k-1}$ dà λ; e poiché $k! = k \cdot (k-1)!$, il rapporto dei fattoriali dà $1/k$. Otteniamo la **ricorrenza**:

$$
\boxed{P(X = k) = P(X = k - 1) \cdot \frac{\lambda}{k}.}
$$

Per passare da un peso al successivo si moltiplica quindi per λ/k. Finché $k < \lambda$ questo fattore è maggiore di 1 e i pesi crescono; quando $k > \lambda$ il fattore è minore di 1 e i pesi decrescono. Il picco della distribuzione si trova quindi attorno a λ.

Con $\lambda = 0{,}61$ partiamo da $P(X = 0) \approx 0{,}54335$. Per arrivare a $k = 1$ moltiplichiamo per $0{,}61$; per arrivare a $k = 2$ moltiplichiamo per $0{,}61/2$. Troviamo circa 0,33144 e 0,10109. Nei calcoli a più passaggi conviene conservare qualche cifra in più e arrotondare soltanto il risultato finale.

Perché la formula sia una PMF, i pesi devono essere non negativi e sommare a 1. La non negatività è evidente. Per la somma usiamo un'identità dell'esponenziale, che qui accettiamo come risultato dell'analisi matematica:

$$
e^{\lambda} = 1 + \lambda + \frac{\lambda^2}{2!} + \frac{\lambda^3}{3!} + \cdots.
$$

Ogni peso della distribuzione di Poisson contiene il fattore comune $e^{-\lambda}$, che possiamo portare fuori dalla somma:

$$\sum_{k=0}^{\infty} P(X=k) = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1.$$

La formula assegna così tutto il peso ai conteggi possibili: è davvero una PMF.

Che cosa abbiamo ottenuto

Dividendo l'intervallo in pezzetti e lasciandoli diventare infiniti, con media totale λ fissata, la distribuzione binomiale si trasforma nella distribuzione di Poisson. La sua PMF è $\lambda^k e^{-\lambda}/k!$ e può essere calcolata un peso alla volta con la ricorrenza λ/k.

14. Tornare ai dati: probabilità e frequenze attese

La formula appena ricavata riguarda il conteggio di un **singolo** corpo-anno e fornisce la probabilità $P(X=k)$. Per confrontarla con la tabella storica dobbiamo esprimerla nella stessa scala dei dati, che riportano **quanti dei 200 corpi-anno** presentano quel valore. Passiamo quindi dalla probabilità al numero atteso di unità moltiplicando per 200:

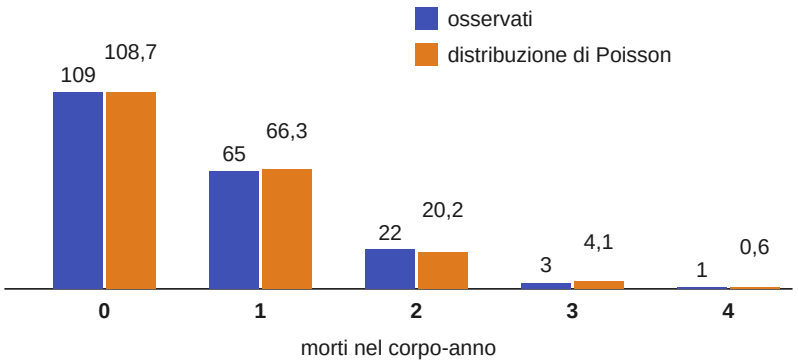
$$\text{numero atteso di corpi-anno con } k \text{ morti} = 200 \cdot P(X=k).$$

Possiamo giustificare questa regola con le indicatrici, che conosciamo bene. Per ogni corpo-anno i, poniamo $J_i = 1$ se il conteggio è k e $J_i = 0$ altrimenti. Il numero di unità nella colonna è la somma $J_1 + \cdots + J_{200}$. Se tutte le unità hanno la stessa distribuzione, ogni indicatrice ha media $P(X=k)$; per linearità la media della somma è $200P(X=k)$. Ricordiamo che per questa media **non occorre indipendenza fra le 200 indicatrici**: la linearità vale comunque.

Con $\lambda = 0{,}61$ calcoliamo i numeri attesi e affianchiamoli ai dati:

Morti nel corpo-anno k	**0**	**1**	**2**	**3**	**4**	**5 o più**
Corpi-anno osservati	109	65	22	3	1	0
Corpi-anno attesi con la distribuzione di Poisson$(0{,}61)$	108,7	66,3	20,2	4,1	0,6	0,1

L'ultima colonna raggruppa tutti i valori da 5 in poi: si calcola come $200[1 - P(X=0) - \cdots - P(X=4)]$. Non è soltanto la probabilità di esattamente cinque eventi.



Dati di Bortkiewicz (1898) e previsione della distribuzione di Poisson con λ = 0,61: ogni coppia di barre quasi coincide.

Questa è la tabella di confronto pubblicata da Bortkiewicz a pagina 25. La formula che Poisson aveva lasciato come risultato di calcolo nel 1837 incontra qui, sessantuno anni dopo, dei dati reali. Il risultato è notevole: **un solo parametro**, ricavato da una sola media, produce una forma vicina a quella osservata.

Il numero atteso 4,1 non significa che un campione debba contenere una frazione di corpo-anno. Una frequenza osservata è sempre intera; la sua media teorica può non esserlo, come il valore atteso di un dado vale 3,5. Inoltre, anche con un modello perfettamente corretto, campioni diversi produrrebbero tabelle diverse. Piccole differenze come 22 contro 20,2 sono del tutto normali.

Una tabella vicina sostiene l'utilità del modello; non dimostra tutte le sue ipotesi.

15. Media e varianza della distribuzione di Poisson

Nella costruzione a pezzetti abbiamo mantenuto fissa la media λ. La PMF permette ora di studiare anche quanto i conteggi si disperdano attorno a quel centro. In questa distribuzione il parametro che fissa la media determina anche la varianza.

Per $X \sim \text{Poisson}(\lambda)$ valgono due proprietà molto semplici:

$$\boxed{\mathbb{E}[X] = \lambda, \qquad \text{Var}(X) = \lambda.}$$

Sono proprietà esatte della **distribuzione teorica**. Con $\lambda = 2$, per esempio, la media del conteggio è 2, la varianza è 2 e la deviazione standard è $\sqrt{2} \approx 1{,}414$.

L'uguaglianza fra media e varianza riguarda i loro *valori numerici*, e non il loro significato. Le interpretazioni restano diverse: la media descrive il centro, la varianza è una media di scarti al quadrato. La deviazione standard, che ha le stesse unità del conteggio, è $\sqrt{\lambda}$.

Questa coincidenza è una peculiarità della distribuzione di Poisson. Nella distribuzione binomiale, per confronto, la varianza è $np(1-p)$, che è più piccola della media np; la distribuzione di Poisson si ottiene quando p è così piccolo che il fattore $1-p$ è praticamente 1. È un'altra faccia del limite dei pezzetti.

Il valore della media è coerente con il modello binomiale a pezzetti, in cui valeva λ per ogni n. Per verificarlo nella distribuzione limite serve però un argomento ulteriore: in generale non possiamo trasferire una media al limite soltanto perché convergono le probabilità dei singoli valori.

Possiamo calcolarla direttamente usando la ricorrenza del §13. Moltiplicando per k entrambi i membri di $P(X=k) = P(X=k-1)\,\lambda/k$ otteniamo, per $k \geq 1$,

$$k\,P(X=k) = \lambda\,P(X=k-1).$$

Sommiamo su tutti i $k \geq 1$. A sinistra compare la media (il termine $k=0$ vale zero); a destra, spostando l'indice di una posizione, compare λ per la somma di *tutti* i pesi, che è 1:

$$\mathbb{E}[X] = \sum_{k=1}^{\infty} k\,P(X=k) = \lambda \sum_{k=1}^{\infty} P(X=k-1) = \lambda \cdot 1 = \lambda.$$

Per la varianza il calcolo è un poco più lungo, e lo facciamo con cura nella Lettura B. Le dimostrazioni sono facoltative; **proprietà e significato sono richiesti all'esame**.

L'uguaglianza fra media e varianza offre anche un controllo sulla dispersione dei dati di Bortkiewicz. La loro media è $\overline{x} = 0{,}61$; se la distribuzione di Poisson è un buon modello, ci aspettiamo una varianza osservata vicina a quel valore. Per calcolarla usiamo gli scarti al quadrato, con la stessa procedura della sezione iniziale, ma pesando con le frequenze relative dei 200 dati.

Conteggio k	Frequenza f_k	$(k-0{,}61)^2$	$f_k(k-0{,}61)^2$
0	109	0,3721	40,5589
1	65	0,1521	9,8865
2	22	1,9321	42,5062
3	3	5,7121	17,1363
4	1	11,4921	11,4921

Leggiamo le colonne: nella terza c'è il quadrato dello scarto dalla media; nella quarta lo scarto al quadrato viene ripetuto f_k volte, perché f_k corpi-anno hanno quel conteggio. L'ultima colonna somma a 121,58. Dividiamo per il numero di osservazioni:

$$v_{\text{dati}} = \frac{121{,}58}{200} = 0{,}6079.$$

Stiamo descrivendo *questi* 200 valori, perciò usiamo il divisore **200**.

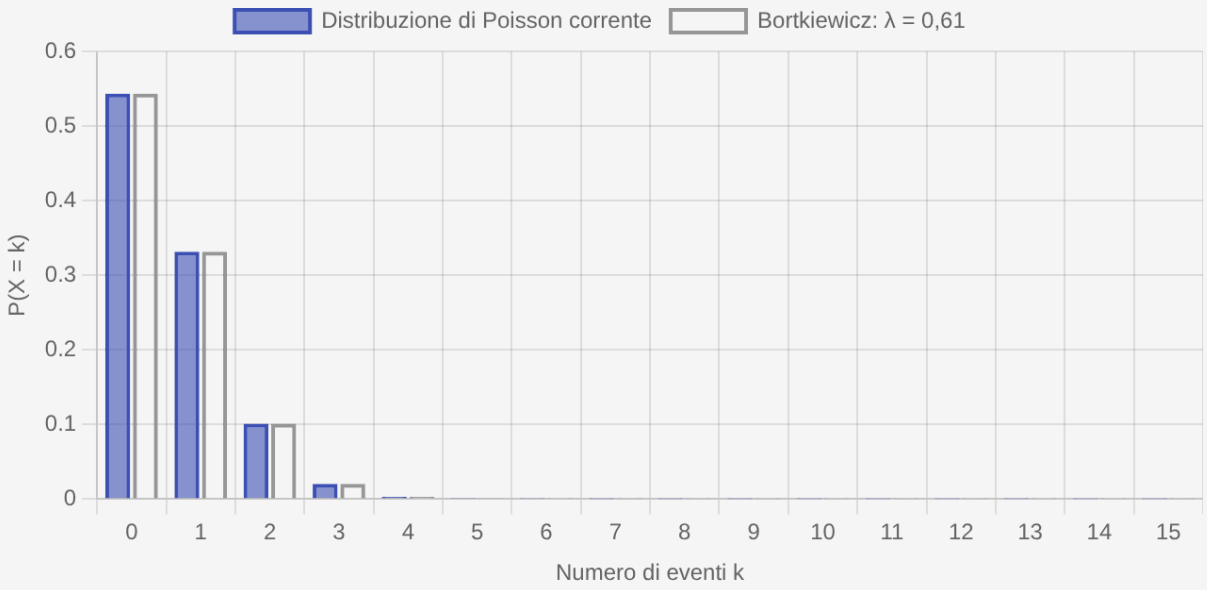
La varianza osservata 0,6079 è vicina alla media osservata 0,61: il confronto è coerente con una distribuzione di Poisson. Attenzione però al *verso* del ragionamento.

- Per una distribuzione di Poisson, media e varianza coincidono.
- Ma **una distribuzione con media e varianza uguali non è necessariamente una distribuzione di Poisson**. Ne vedrai un controesempio nell'esercizio 6.
- Inoltre, un campione finito non deve riprodurre esattamente l'uguaglianza teorica.

È un controllo utile, non una certificazione del modello.

Esplora: centro, dispersione e probabilità dello zero

Il riferimento è la distribuzione di Poisson$(0{,}61)$. Aumenta λ e osserva come la massa si sposta a destra e si allarga. La probabilità di zero eventi diminuisce. Prima di usare il cursore, prova a confrontare e^{-1}, e^{-2} ed e^{-3}: in quale di questi casi la probabilità di zero scende sotto il 5%?



Un solo cursore governa tutto: posizione, larghezza e probabilità dello zero.

E[X] = λ: **0.61** Var(X) = λ: **0.61** P(X = 0) = e^(−λ): **0.5434**

corpi-anno attesi con 0 eventi su 200: **108.7**

Con $\lambda = 3$, $e^{-3} \approx 0{,}0498$: meno di un intervallo su venti è vuoto, secondo il modello. Il grafico si ferma a 15; con λ grande una parte del peso è oltre il bordo, e non scompare dalla distribuzione.

16. Laboratorio: ricostruire tabella e dispersione

I conti dei §9–15 si possono ripetere a partire dalle sole frequenze osservate. Nel programma qui sotto, ogni conteggio e la sua frequenza sono registrati nel dizionario `osservati`: modificandolo possiamo studiare un altro insieme di dati con lo stesso procedimento.

Il codice calcola la media e la usa come parametro della distribuzione di Poisson. Poi ricostruisce i numeri attesi e calcola la varianza con **gli scarti al quadrato**, come nella tabella. I commenti collegano le istruzioni ai passaggi svolti a mano.

> *Blocco di codice di 41 righe omesso dalla versione PDF: lo trovi, e puoi eseguirlo direttamente nel browser, nella versione online del capitolo.*

Il grafico confronta le colonne da 0 a 4. La distribuzione di Poisson assegna anche un piccolo peso a «5 o più»: quelle barre non sono disegnate. L'assenza di valori oltre 4 nel campione non rende impossibili quei conteggi nel modello.

Esplorazione facoltativa — Dai 10 corpi comparabili a tutti e 14

Come spiegato nel §9, i dati storici riguardano 14 corpi d'armata osservati per 20 anni, dal 1875 al 1894. Nel confronto principale abbiamo usato soltanto i **10 corpi con esposizioni al rischio più simili**, per un totale di $10 \cdot 20 = 200$ corpi-anno. Possiamo ripetere il calcolo includendo anche gli altri quattro: le osservazioni diventano $14 \cdot 20 = 280$.

La scelta dei 10 corpi tiene conto della loro composizione e, in particolare, della consistenza della cavalleria. Bortkiewicz esclude dal confronto principale la Guardia e i corpi I, VI e XI; nella nota a p. 24 ricorda, per esempio, che la Guardia aveva **40 squadroni di cavalleria contro i 20 della dotazione normale**. Un corpo con più cavalleria può avere più cavalli e più occasioni di contatto fra uomini e animali, quindi più occasioni di incidente. Due corpi osservati per un anno rappresentano la stessa durata, ma **non necessariamente la stessa esposizione al rischio**: anche a parità di rischio per singolo contatto, il numero medio annuo di incidenti può essere diverso.

Per includere tutti i corpi, sostituisci il blocco iniziale del laboratorio, dal commento su Bortkiewicz fino all'`assert`, con:

```
# Bortkiewicz (1898): tutti i 14 corpi d'armata per 20 anni.
osservati = {0: 144, 1: 91, 2: 32, 3: 11, 4: 2}
corpi_anno = sum(osservati.values())
morti = sum(k * f for k, f in osservati.items())
lam = morti / corpi_anno
assert corpi_anno == 280 and morti == 196
```

Le chiavi del dizionario sono i conteggi di morti; i valori sono le loro frequenze. Per esempio, `0: 144` significa che **144 corpi-anno non registrarono alcun morto**, mentre `2: 32` significa che 32 corpi-anno registrarono due morti ciascuno. Le frequenze sommano a 280; i morti complessivi sono 196. L'`assert` verifica questi nuovi totali: quello precedente, riferito ai 10 corpi, non sarebbe più soddisfatto.

Aggiorna anche l'etichetta della seconda serie del grafico, da `"Attesi con la distribuzione di Poisson(0,61)"` a `"Attesi con la distribuzione di Poisson(0,70)"`, e il commento sul divisore della varianza, ora **280**. Il programma ricalcola automaticamente media, varianza e frequenze attese a partire dai nuovi dati.

Eseguendo di nuovo il codice, ottieni:

Dati inclusi	Corpi-anno	Media	Varianza descrittiva
10 corpi comparabili	200	0,61	0,6079
Tutti i 14 corpi	280	0,70	0,7600

Nei 10 corpi media e varianza sono quasi uguali; includendo tutti e 14, la varianza supera la media. La maggiore dispersione è compatibile con esposizioni al rischio meno omogenee: corpi con medie diverse, riuniti nello stesso insieme, possono produrre più variabilità di quella prevista da una distribuzione di Poisson con media comune. Questo confronto, da solo, non dimostra la causa della differenza, ma suggerisce di riesaminare l'ipotesi di omogeneità.

17. Tasso e parametro: fissare le unità

Il valore 0,61 si riferisce a un corpo osservato per un anno. Se il periodo fosse di due anni, a parità di condizioni ci aspetteremmo il doppio degli eventi. Anche nelle applicazioni informatiche la finestra può cambiare: una domanda riguarda

gli arrivi in un secondo, un'altra quelli in un minuto. Per scegliere il parametro dobbiamo distinguere la frequenza degli arrivi dalla durata dell'osservazione.

Un **tasso** indica quanti eventi arrivano in media *per unità di tempo*. Il **parametro** della distribuzione di Poisson indica invece quanti eventi attendiamo *nell'intervallo scelto*. Per evitare confusione chiamiamo il tasso r e la durata t:

$$\boxed{\lambda = rt.}$$

Se r è in richieste al secondo, t deve essere in secondi. Le unità di tempo si semplificano e otteniamo il numero medio di richieste nell'intervallo, che non ha dimensioni di tempo: è un conteggio.

Supponiamo un flusso con tasso costante $r = 3$ richieste al secondo e con le ipotesi del modello di Poisson valide su tutti gli intervalli considerati.

Durata t	Media nell'intervallo $\lambda = rt$	Distribuzione del conteggio
Mezzo secondo	$3 \cdot 0{,}5 = 1{,}5$	Distribuzione di Poisson$(1{,}5)$
Un secondo	$3 \cdot 1 = 3$	Distribuzione di Poisson(3)
Dieci secondi	$3 \cdot 10 = 30$	Distribuzione di Poisson(30)
Un minuto	$3 \cdot 60 = 180$	Distribuzione di Poisson(180)

Per zero richieste, in mezzo secondo la probabilità è $e^{-1{,}5} \approx 0{,}2231$; in un secondo è $e^{-3} \approx 0{,}0498$. Un intervallo più lungo offre più occasioni di arrivo, quindi è meno probabile che resti vuoto.

Conoscere soltanto la distribuzione del conteggio in un secondo **non basta** a dedurre quella in ogni altra durata. Stiamo assumendo un unico modello di arrivi, con tasso stabile e incrementi indipendenti. È questa ipotesi sul flusso a giustificare la conversione del modello, oltre alla semplice conversione della media.

L'intervallo non deve per forza essere temporale. Può essere spaziale: refusi per pagina, difetti per metro di cavo, errori per megabyte. Il ragionamento è identico, con le unità appropriate. Prima di inserire λ nella formula, scrivi sempre **a quale unità di osservazione si riferisce**. È la domanda che previene più errori in questo capitolo.

Atto V — Usare i modelli nei sistemi

18. Richieste a un server: calcolare un picco

Supponiamo di voler dimensionare un server per accettare fino a cinque richieste al secondo. La media degli arrivi non basta a valutare questa scelta: dobbiamo sapere quanto spesso il conteggio supera la soglia di cinque.

Immaginiamo 10.000 utenti. In un secondo ciascuno può inviare una richiesta con probabilità $0{,}0003$, indipendentemente dagli altri. In questo modello il conteggio segue esattamente una distribuzione binomiale e la sua media è:

$$10000 \cdot 0{,}0003 = 3.$$

Il numero elevato di prove e la piccola probabilità di invio permettono di approssimare il conteggio con una distribuzione di Poisson(3). Indichiamo con X il conteggio in questo modello approssimato.

La soglia viene superata quando arrivano **più di cinque richieste in un secondo**: l'evento è $X > 5$, cioè $X \geq 6$. Per calcolarne la probabilità conviene passare dal complementare, che comprende soltanto i sei valori da 0 a 5:

$$\begin{aligned} P(X > 5) &= 1 - P(X \leq 5) \\ &= 1 - \sum_{k=0}^{5} \frac{3^k e^{-3}}{k!} \\ &= 1 - e^{-3}\left(1 + 3 + \frac{9}{2} + \frac{27}{6} + \frac{81}{24} + \frac{243}{120}\right) \\ &\approx 0{,}0839. \end{aligned}$$

Controlliamo la somma tra parentesi: $1 + 3 + 4{,}5 + 4{,}5 + 3{,}375 + 2{,}025 = 18{,}4$. Moltiplicata per $e^{-3} \approx 0{,}0498$ dà circa $0{,}916$, e il complementare è $0{,}084$.

Nel modello, circa l'8,4% degli intervalli di un secondo supera cinque arrivi. Se una regola di capacità accetta al massimo cinque arrivi per intervallo, questa è la probabilità di superare quella soglia.

Per valutare le prestazioni effettive del server occorre conoscere anche i tempi di servizio, le regole della coda e la distribuzione degli arrivi all'interno del secondo. Il conteggio ci ha permesso di valutare la soglia di cinque arrivi; queste altre informazioni servono a capire come il sistema riesca a smaltirli.

19. Quando il modello perde credibilità

La stima appena ottenuta dipende dalle ipotesi sugli utenti: ciascuno invia indipendentemente dagli altri, con una probabilità che resta la stessa. Un gran numero di utenti, da solo, non assicura queste condizioni. Nella costruzione a pezzetti avevamo richiesto eventi singoli, un tasso stabile e indipendenza dei conteggi in intervalli disgiunti; nei sistemi reali possiamo invece incontrare:

- **attività a raffiche**, con molti client influenzati dallo stesso evento;
- **tassi variabili**, per esempio differenze fra notte e giorno;
- **effetti a catena**, nei quali una richiesta fallita genera altri tentativi;
- **cause comuni**, come un problema elettrico che guasta più componenti insieme.

Questi meccanismi possono produrre conteggi **più dispersi** di una distribuzione di Poisson con la stessa media. Si parla di **sovradispersione** quando la varianza supera la media. Nei dati, una differenza consistente fra varianza e media invita a cercare eterogeneità, dipendenza o altri aspetti mancanti nel modello.

Un tasso variabile non esclude ogni possibile uso della distribuzione di Poisson. Intervalli omogenei possono avere ciascuno un modello adatto, ma con parametri diversi: per esempio una distribuzione di Poisson di media 1 di notte e una di media 5 di giorno. Mescolare quei conteggi e attribuire a tutti un unico parametro può invece nascondere proprio la variabilità che ci interessa.

Il confronto tra media e varianza va interpretato con misura:

- piccole differenze sono normali nei campioni finiti;
- una differenza grande richiede un'indagine;
- un'uguaglianza non basta a identificare la distribuzione.

Esistono anche conteggi **meno** dispersi della distribuzione di Poisson, per esempio quando gli eventi si ostacolano o vengono regolati.

20. Laboratorio: traffico regolare e traffico a raffiche

Riprendiamo i 10.000 utenti dell'esempio del server e simuliamo 20.000 secondi. Il programma permette di confrontare una probabilità di invio costante con una che aumenta, per tutti gli utenti insieme, in alcuni secondi. Possiamo così osservare quanto cambia la dispersione quando introduciamo una causa comune di maggiore attività.

Partiamo da `raffica = False`: ogni secondo ha la stessa probabilità di invio per utente. Prima di eseguire, prevedi la media e chiediti se la varianza sarà vicina a quella della distribuzione di Poisson(3).

```
from math import exp, factorial

import numpy as np

rng = np.random.default_rng(42)
utenti = 10000      # client che possono inviare una richiesta
p = 0.0003          # probabilità che uno di loro la invii in 1 secondo
secondi = 20000     # quanti secondi osserviamo
raffica = False     # prova True: a volte tutti diventano più attivi

lam = utenti * p    # richieste attese al secondo
p_secondo = np.full(secondi, p)
if raffica:
    # Nel 10% dei secondi ogni client è 5 volte più attivo.
    p_secondo[rng.random(secondi) < 0.1] = 5 * p
# Ogni secondo: quanti dei 10000 client inviano (una distribuzione binomiale).
richieste = rng.binomial(utenti, p_secondo)

media = richieste.mean()
print(f"Media di base n * p: {lam:.1f}")
media_teorica = lam * (1.4 if raffica else 1)
print(f"Media teorica del modello scelto: {media_teorica:.1f}")
print(f"Media osservata: {media:.3f}")
print(f"Varianza osservata: {richieste.var():.3f}")
# Confronto con la distribuzione di Poisson che ha la stessa media dei dati.
print(" k  frequenza  distribuzione di Poisson")
for k in range(9):
    freq = np.mean(richieste == k)
    teoria = exp(-media) * media ** k / factorial(k)
    print(f"{k:2d}  {freq:9.4f}  {teoria:7.4f}")
```

La simulazione genera conteggi binomiali; il confronto con la distribuzione di Poisson è una previsione approssimata. Con `raffica = False`, media e varianza sono vicine a 3 e le frequenze sono vicine ai pesi teorici, con le oscillazioni che ci aspettiamo da un campionamento.

Ora imposta `raffica = True`. Nel 10% dei secondi la probabilità di invio di **tutti** gli utenti diventa cinque volte maggiore. Un secondo tranquillo ha media 3; un secondo attivo ha media 15. Prima di guardare l'output, calcola a mano la nuova media pesando i due tipi di secondo:

$$0{,}9 \cdot 3 + 0{,}1 \cdot 15 = 4{,}2.$$

Poi prevedi la varianza. Sarà vicina a 17, molto maggiore di 4,2. Il programma confronta i pesi osservati con una distribuzione di Poisson che usa la **nuova media osservata**, quindi la differenza non nasce dall'aver dimenticato di aggiornare λ. Nasce dalla *mescolanza* di secondi con attività diverse.

Un ultimo punto, sottile ma importante. Condizionatamente al tipo di secondo, gli utenti restano indipendenti nel codice. Ma se non conosciamo quel tipo, l'attività comune li collega: osservare molte richieste da un gruppo di utenti è un indizio che anche gli altri siano nel regime attivo. Il modello che tratta ogni secondo come identico agli altri perde questa informazione, e per questo sottostima le code.

21. Quale distribuzione: geometrica, binomiale o di Poisson?

Gli esempi dei retry e degli arrivi parlano entrambi di richieste, ma contano grandezze diverse. Per scegliere una distribuzione conviene quindi precisare la domanda, completando la frase **«La variabile conta…»**, e dichiarare ciò che teniamo fissato e le ipotesi che facciamo. La tabella raccoglie le tre possibilità incontrate fin qui:

	Geometrica (p)	**Distribuzione binomiale** (n, p)	**Distribuzione di Poisson** (λ)
Domanda	Quante prove fino al primo successo?	Quanti successi in n prove?	Quanti eventi in un intervallo?
Che cosa è fissato	Probabilità per prova e traguardo del primo successo	Numero di prove e probabilità per prova	Intervallo e media del conteggio
Valori	$1, 2, 3, \ldots$	$0, 1, \ldots, n$	$0, 1, 2, \ldots$
PMF	$(1-p)^{k-1}p$	$\binom{n}{k}p^k(1-p)^{n-k}$	$\lambda^k e^{-\lambda}/k!$
Media	$1/p$	np	λ
Esempio	Tentativi fino alla prima risposta	Richieste riuscite fra 10 tentativi	Arrivi in un secondo

La Geometrica conta un'attesa in **prove discrete**, non una durata continua in secondi. Possiamo tradurla in durata se conosciamo i tempi delle prove, come abbiamo fatto nel §8.

La distribuzione di Poisson conta eventi in una finestra: **non** è la distribuzione del tempo fino all'evento successivo. Quel tempo avrà un modello continuo proprio, che incontreremo più avanti.

Per una richiesta che riesce con probabilità 0,9:

- il numero di tentativi fino al successo è **Geometrico**;
- il numero di successi in dieci tentativi indipendenti ha **distribuzione binomiale**;
- il numero di richieste in arrivo in un secondo può seguire una **distribuzione di Poisson**, se il meccanismo degli arrivi lo giustifica.

Il fatto che tutti e tre gli esempi parlino di richieste non determina il modello: lo determinano *la domanda e le ipotesi.*

Sosta di verifica

Per ciascuna situazione, completa la frase «La variabile conta…» e indica il modello: (a) i pacchetti persi in un minuto su un collegamento stabile; (b) il numero di lanci di un dado fino al primo 6; (c) i 6 ottenuti in 20 lanci di un dado.

Risposta

(a) Conta eventi in un intervallo, con tasso stabile: **distribuzione di Poisson**, con parametro uguale alla media dei pacchetti persi in un minuto.

(b) Conta prove fino al primo successo, con $p = 1/6$: **Geometrica**$(1/6)$, media 6.

(c) Conta successi in un numero fissato di prove: **distribuzione binomiale**$(20, 1/6)$, media $20/6 \approx 3{,}33$.

Che cosa abbiamo ottenuto

Abbiamo imparato a riconoscere tre domande diverse sugli stessi eventi: *quanto aspetto?* (Geometrica), *quanti successi in n prove?* (distribuzione binomiale), *quanti eventi in un intervallo?* (distribuzione di Poisson). La scelta del modello dipende da ciò che è fissato e da ciò che osserviamo, e non dalla parola «richieste».

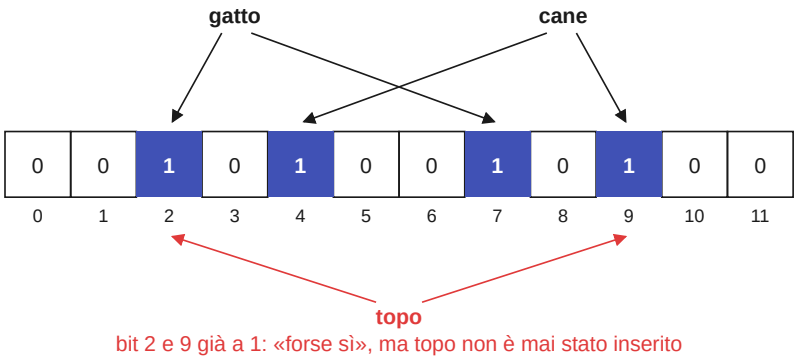
Lettura A — Il filtro di Bloom: quanto costa rispondere «forse»?

Approfondimento facoltativo, fuori dal nucleo d'esame orale.

Supponi di mantenere una lista molto grande di indirizzi web. Prima di consultare una struttura costosa (un database, un disco lento), vorresti un controllo rapido che dica se un indirizzo *può* essere presente. Un **filtro di Bloom** scambia un po' di precisione con un grande risparmio di memoria: risponde «sicuramente assente» oppure «forse presente».

Il filtro usa m bit, inizialmente tutti a 0, e k funzioni hash. Ciascuna funzione associa un elemento a una posizione fra 0 e $m - 1$.

- Per **inserire** un elemento, mettiamo a 1 i suoi k bit.
- Per **interrogarlo**, guardiamo quei k bit. Se anche uno solo è 0, rispondiamo «assente». Se sono tutti 1, rispondiamo «forse presente».



Due elementi inseriti con due funzioni hash ciascuno; un terzo elemento, mai inserito, trova accesi tutti i suoi bit: falso positivo.

Guarda la figura con attenzione: *gatto* e *cane* accendono ciascuno due bit. L'elemento *topo*, mai inserito, ha per caso proprio i bit 2 e 9, già accesi dagli altri due. Il filtro risponde «forse», ma la risposta è sbagliata.

Nel filtro standard, senza cancellazioni, nessuno spegne un bit già acceso. Ne seguono due fatti:

- un elemento inserito trova sempre tutti i propri bit a 1: **non ci sono falsi negativi**;
- un elemento mai inserito può trovare i propri bit accesi da altri elementi: è un **falso positivo**.

La domanda quantitativa è dunque: *con che frequenza capita un falso positivo?* La risolviamo in due passi.

La probabilità di un falso positivo

Supponiamo di inserire n elementi distinti e modelliamo tutti i risultati hash come indipendenti e uniformi. Gli inserimenti producono kn scelte di posizione. Fissiamo un bit: ogni scelta lo colpisce con probabilità $1/m$ e lo manca con probabilità $1 - 1/m$.

Per restare a zero, il bit deve essere mancato tutte le kn volte. Per indipendenza moltiplichiamo:

$$P(\text{bit a zero}) = \left(1 - \frac{1}{m}\right)^{kn}.$$

Il numero di colpi su quel bit ha distribuzione binomiale con media kn/m. Ritroviamo così il meccanismo del §12: molte occasioni, ciascuna con una piccola probabilità di colpire una posizione fissata. Quando l'approssimazione con la distribuzione di Poisson è adatta, la probabilità di zero colpi è circa $e^{-kn/m}$. Quindi:

$$P(\text{bit a uno}) = 1 - \left(1 - \frac{1}{m}\right)^{kn} \approx 1 - e^{-kn/m}.$$

Un falso positivo richiede che tutte le k posizioni di un elemento assente risultino accese. Per moltiplicare le k probabilità dobbiamo trattare questi stati come indipendenti. È **un'ulteriore approssimazione**: i bit condividono gli stessi inserimenti e le posizioni interrogate possono coincidere. Con questa approssimazione otteniamo:

$$P(\text{falso positivo}) \approx \left(1 - e^{-kn/m}\right)^{k}.$$

Con $n = 100$ elementi, $m = 1000$ bit e $k = 7$ funzioni hash, procediamo per passi:

$$\frac{kn}{m} = 0{,}7, \qquad 1 - e^{-0{,}7} \approx 0{,}5034, \qquad (0{,}5034)^7 \approx 0{,}0082.$$

Il valore è circa lo 0,82% **fra le interrogazioni di elementi assenti**, nel modello. Fai attenzione a non leggerlo diversamente: non è la probabilità che un «forse presente» sia sbagliato. Per quella domanda servirebbe sapere anche quanto spesso interroghiamo elementi presenti e assenti.

Il vettore occupa 1000 bit per 100 elementi, cioè 10 bit per elemento, oltre alla gestione delle funzioni hash. Dopo un «forse» consultiamo la struttura che conosce la risposta esatta. Il filtro serve a evitare molti controlli costosi, non a sostituire sempre quel controllo. Con una frequenza di falsi positivi dello 0,8%, circa 99 «assente» su 100 interrogazioni di elementi assenti vengono risolti subito, senza toccare il disco.

Lettura B — Perché il limite e i momenti hanno proprio quella forma

Approfondimento facoltativo. Nel percorso d'esame sono richiesti l'idea dei pezzetti, il caso di zero eventi e le proprietà finali della distribuzione di Poisson.

Nel §13 abbiamo enunciato la PMF della distribuzione di Poisson passando al limite nel modello a pezzetti. Per ricavare quel risultato studieremo separatamente i fattori della PMF della distribuzione binomiale; dalla nuova PMF potremo poi calcolare media e varianza.

B.1. Il limite binomiale, un fattore alla volta

Fissiamo $\lambda > 0$ e un intero $k \geq 0$. Consideriamo $X_n \sim \text{Binomiale}(n, \lambda/n)$ con $n > \lambda$ e $n \geq k$. Il punto essenziale, da non perdere di vista, è che n **cresce, mentre** k **e** λ **restano fissi**.

La PMF della distribuzione binomiale è:

$$P(X_n = k) = \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}.$$

Il coefficiente si scrive $\binom{n}{k} = \dfrac{n(n-1)\cdots(n-k+1)}{k!}$: al numeratore ci sono k fattori. Anche $(\lambda/n)^k$ contiene k copie di n al denominatore. Possiamo quindi abbinare ciascun fattore del numeratore a una copia di n. Separiamo inoltre la potenza $n - k$ in due parti, n e $-k$:

$$P(X_n = k) = \underbrace{\frac{n(n-1)\cdots(n-k+1)}{n^k}}_{A_n} \cdot \frac{\lambda^k}{k!} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^{n}}_{B_n} \cdot \underbrace{\left(1 - \frac{\lambda}{n}\right)^{-k}}_{C_n}.$$

Abbiamo spezzato un'espressione complicata in quattro pezzi. Uno ($\lambda^k/k!$) non dipende da n. Degli altri tre studiamo il limite separatamente.

Per $k = 0$ il prodotto in A_n è vuoto e vale 1. Per $k \geq 1$ dividiamo ciascun fattore del numeratore per un n:

$$A_n = 1 \cdot \left(1 - \frac{1}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right) \longrightarrow 1.$$

Ogni fattore tende a 1 e il **numero di fattori è fisso** (k, che non cresce con n). Un prodotto di un numero fisso di quantità che tendono a 1 tende a 1.

Il gruppo B_n tende a $e^{-\lambda}$ per il limite già usato nel §12. Il gruppo C_n tende a 1: la base $1 - \lambda/n$ tende a 1 e l'esponente $-k$ è fissato, quindi la potenza tende a $1^{-k} = 1$.

Moltiplicando i limiti otteniamo:

$$P(X_n = k) \longrightarrow 1 \cdot \frac{\lambda^k}{k!} \cdot e^{-\lambda} \cdot 1 = \frac{\lambda^k e^{-\lambda}}{k!}.$$

Possiamo leggere il significato di ciascun pezzo. Il fattoriale rimasto al denominatore viene dalla scelta dei pezzetti: scegliere k posizioni *senza ordine* divide per i $k!$ ordinamenti dello stesso insieme. L'esponenziale deriva invece dal prodotto delle probabilità dei moltissimi pezzetti vuoti.

Per una distribuzione binomiale concreta usiamo la distribuzione di Poisson(np) come **approssimazione** quando il regime lo consente. «n grande e p piccolo» descrive il meccanismo, ma non è una garanzia universale sulla precisione di ogni domanda: anche la probabilità richiesta e l'accuratezza necessaria contano. Se il modello esatto è disponibile e la differenza è rilevante, possiamo confrontare direttamente le due probabilità.

B.2. Media e varianza dalla PMF

Calcoliamo i momenti dalla PMF della distribuzione di Poisson. In questo modo non occorre trasferire al limite quelli della distribuzione binomiale. Cominciamo dalla media, che per definizione è:

$$\mathbb{E}[X] = \sum_{k=0}^{\infty} k \frac{\lambda^k e^{-\lambda}}{k!} = \sum_{k=1}^{\infty} k \frac{\lambda^k e^{-\lambda}}{k!}.$$

Il termine $k = 0$ non contribuisce (è moltiplicato per 0), quindi la somma parte da 1. Per $k \geq 1$ vale $k! = k\,(k-1)!$, quindi $k/k! = 1/(k-1)!$. Raccogliamo inoltre un fattore λ dalla potenza e il fattore comune $e^{-\lambda}$:

$$\mathbb{E}[X] = \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!}.$$

Poniamo $j = k - 1$. Il nuovo indice comincia da 0, e la somma diventa $\sum_{j=0}^{\infty} \lambda^j / j! = e^{\lambda}$. Perciò:

$$\mathbb{E}[X] = \lambda e^{-\lambda} e^{\lambda} = \lambda.$$

Per la varianza ci serve la media di X^2. Il calcolo diretto di $\sum k^2 P(X=k)$ è scomodo. Conviene invece calcolare $\mathbb{E}[X(X-1)]$, perché il fattoriale contiene già il prodotto $k(k-1)$ che si semplifica bene. I termini con $k = 0$ e $k = 1$ sono nulli, quindi la somma parte da 2:

$$\begin{aligned} \mathbb{E}[X(X-1)] &= \sum_{k=2}^{\infty} k(k-1) \frac{\lambda^k e^{-\lambda}}{k!} \\ &= \lambda^2 e^{-\lambda} \sum_{k=2}^{\infty} \frac{\lambda^{k-2}}{(k-2)!} \\ &= \lambda^2 e^{-\lambda} e^{\lambda} = \lambda^2. \end{aligned}$$

Nella seconda riga abbiamo usato $k! = k(k-1)(k-2)!$ e raccolto λ^2. Nella terza abbiamo cambiato indice con $j = k - 2$. Le somme sono di termini non negativi e i risultati sono finiti.

Ora torniamo a X^2 con l'identità $X^2 = X(X-1) + X$, che si verifica sviluppando. Per linearità:

$$\mathbb{E}[X^2] = \mathbb{E}[X(X-1)] + \mathbb{E}[X] = \lambda^2 + \lambda.$$

Usando l'identità della varianza ricavata nella Lettura C, troviamo:

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = (\lambda^2 + \lambda) - \lambda^2 = \lambda.$$

Abbiamo verificato entrambe le proprietà senza dover scambiare un limite di distribuzioni con un valore atteso. Il risultato conferma che una distribuzione di Poisson ha media e varianza entrambe uguali a λ.

Lettura C — Due strumenti ulteriori per la varianza

Approfondimento facoltativo, non richiesto all'esame. Per il percorso principale si usa la definizione con gli scarti al quadrato.

Questa lettura riparte dalla definizione iniziale. Prima ricava un'identità utile nei calcoli; poi la applica a una somma di indicatrici, mostrando esattamente dove l'indipendenza interviene nella varianza della distribuzione binomiale.

C.1. La media dei quadrati e il quadrato della media

La definizione con gli scarti spiega il significato della varianza. Per fare i conti, però, è spesso comodo disporre di una formula che usi la media di X e la media di X^2. Ricaviamola senza saltare i passaggi.

Partiamo dallo scarto al quadrato che compare nella definizione. La quantità μ è la media di X: una volta fissato il modello, è un numero determinato. Il valore di X cambia con l'esito dell'esperimento, mentre μ rimane lo stesso. Possiamo perciò trattare μ come una costante e applicare l'identità algebrica del quadrato di una differenza:

$$(X - \mu)^2 = X^2 - 2\mu X + \mu^2.$$

Ora facciamo la media dei due lati. A sinistra troviamo, per definizione, la varianza. A destra usiamo la linearità per separare i tre termini: il coefficiente costante del termine centrale esce dal valore atteso, mentre l'ultimo termine, essendo costante, ha media uguale a sé stesso:

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - 2\mu\mathbb{E}[X] + \mu^2.$$

Poiché $\mathbb{E}[X] = \mu$, il secondo termine è $-2\mu^2$. Sommandolo all'ultimo resta $-\mu^2$:

$$\boxed{\mathrm{Var}(X) = \mathbb{E}[X^2] - \mu^2.}$$

La formula è spesso comoda nei calcoli, ma richiede attenzione all'ordine delle operazioni. $\mathbb{E}[X^2]$ significa: **prima eleva al quadrato ciascun risultato, poi fai la media**. Il termine $\mu^2 = (\mathbb{E}[X])^2$ significa invece: **prima fai la media dei risultati, poi eleva al quadrato quel numero**.

Le parentesi indicano dunque due procedimenti diversi. Non possiamo scambiarli: in generale producono numeri diversi, e la formula ci dice che la loro differenza è proprio la varianza.

Per calcolare $\mathbb{E}[X^2]$ applichiamo la regola LOTUS con $g(x) = x^2$: non serve ricostruire da zero la distribuzione del quadrato. Usiamo gli stessi pesi della PMF di X, applicandoli ai valori elevati al quadrato:

$$\mathbb{E}[X^2] = \sum_x x^2 p_X(x).$$

Seguiamo entrambi i procedimenti nel pagamento che vale 0 oppure 10. Per trovare $\mathbb{E}[X^2]$, trasformiamo i pagamenti in $0^2 = 0$ e $10^2 = 100$, mantenendo probabilità $1/2$ e $1/2$. La media dei quadrati è quindi $\mathbb{E}[X^2] = 0^2 \cdot 1/2 + 10^2 \cdot 1/2 = 50$.

Per trovare il quadrato della media, partiamo invece dalla media dei pagamenti, che è 5, ed eleviamo quel numero al quadrato: otteniamo 25. Sottraendo troviamo $50 - 25 = 25$, lo stesso valore già ricavato con gli scarti. In particolare, nel primo conto abbiamo elevato al quadrato i **valori**, lasciando inalterati i loro pesi probabilistici.

Applichiamo lo stesso procedimento a una variabile bernoulliana I di parametro p, perché ci servirà per il conteggio binomiale. La sua media è p, come per ogni indicatrice. Per usare la nuova formula dobbiamo trovare anche la media di I^2.

Qui il quadrato è particolarmente semplice: i soli valori possibili sono 0 e 1, e valgono $0^2 = 0$ e $1^2 = 1$. Qualunque sia l'esito dell'esperimento, il quadrato del bit è dunque uguale al bit stesso: $I^2 = I$. Di conseguenza, anche le loro medie coincidono: $\mathbb{E}[I^2] = \mathbb{E}[I] = p$.

Sostituendo la media p e la media del quadrato p nella formula della varianza, otteniamo:

$$\mathrm{Var}(I) = p - p^2 = p(1-p).$$

C.2. La varianza della distribuzione binomiale: dove serve l'indipendenza

Consideriamo n prove indipendenti, ciascuna con probabilità di successo p. L'indicatrice I_i vale 1 se la prova i ha successo e 0 altrimenti. Il numero totale di successi è quindi:

$$X = I_1 + I_2 + \cdots + I_n.$$

Sappiamo già che X ha distribuzione binomiale e ha media $\mathbb{E}[X] = np$. Ora vogliamo misurare quanto il conteggio si disperde attorno a questa media.

Nella sezione precedente abbiamo trovato la formula:

$$\mathrm{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

Il secondo termine è già noto: basta elevare al quadrato la media np. Il primo termine, invece, richiede un nuovo conto. Dobbiamo trovare **la media del quadrato del numero di successi**.

Prima di usare le sommatorie, prendiamo soltanto tre indicatrici. Moltiplicare la somma per sé stessa significa moltiplicare ogni termine della prima parentesi per ogni termine della seconda:

$$\begin{aligned}(I_1 + I_2 + I_3)^2 &= (I_1 + I_2 + I_3)(I_1 + I_2 + I_3) \\ &= I_1^2 + I_1 I_2 + I_1 I_3 \\ &\quad + I_2 I_1 + I_2^2 + I_2 I_3 \\ &\quad + I_3 I_1 + I_3 I_2 + I_3^2.\end{aligned}$$

Ci sono tre quadrati, uno per ogni indicatrice. Gli altri termini si possono raccogliere a due a due: $I_1 I_2 = I_2 I_1$, e lo stesso vale per le altre coppie. Otteniamo:

$$(I_1 + I_2 + I_3)^2 = I_1^2 + I_2^2 + I_3^2 + 2I_1I_2 + 2I_1I_3 + 2I_2I_3.$$

Con n indicatrici succede la stessa cosa: abbiamo n quadrati e due copie del prodotto per ogni coppia distinta. La scrittura compatta è:

$$X^2 = \sum_{i=1}^{n} I_i^2 + 2 \sum_{1 \le i < j \le n} I_i I_j.$$

Il vincolo $i < j$ elenca ogni coppia una volta sola; il fattore 2 tiene conto dei due prodotti che abbiamo raccolto. Per trovare la media di X^2 studieremo separatamente i quadrati e i prodotti.

Un'indicatrice assume soltanto i valori 0 e 1. Elevandoli al quadrato otteniamo ancora 0 e 1: per ogni esito vale dunque $I_i^2 = I_i$.

Di conseguenza:

$$\mathbb{E}[I_i^2] = \mathbb{E}[I_i] = p.$$

Questo passaggio non richiede indipendenza: riguarda una sola indicatrice alla volta. Poiché i quadrati sono n e ciascuno ha media p, il loro contributo complessivo sarà np.

Prendiamo due prove diverse, i e j. Che cosa registra il prodotto I_iI_j? Possiamo verificarlo su tutti i valori dei due bit:

I_i	I_j	I_iI_j
0	0	0
0	1	0
1	0	0
1	1	1

Il prodotto vale 1 soltanto quando **entrambe le prove hanno successo**. È quindi l'indicatrice di quell'evento, e la sua media è la probabilità dell'evento stesso:

$$\mathbb{E}[I_iI_j] = P(I_i = 1,\ I_j = 1).$$

È ora che usiamo l'indipendenza. Nel modello binomiale, conoscere il successo della prova i non cambia la probabilità di successo della prova j. Possiamo quindi moltiplicare le due probabilità:

$$\begin{aligned} P(I_i = 1,\ I_j = 1) &= P(I_i = 1)\,P(I_j = 1) \\ &= p \cdot p \\ &= p^2. \end{aligned}$$

Abbiamo così trovato $\mathbb{E}[I_i I_j] = p^2$ per ogni coppia distinta. Sapere soltanto che ciascuna prova ha probabilità di successo p non basterebbe: serve anche conoscere la probabilità dei due successi insieme.

Torniamo all'espansione di X^2 e facciamo la media. La linearità permette di separare tutti gli addendi:

$$\mathbb{E}[X^2] = \sum_{i=1}^{n} \mathbb{E}[I_i^2] + 2 \sum_{1 \le i < j \le n} \mathbb{E}[I_i I_j].$$

Nella prima somma ci sono n termini, tutti uguali a p. Nella seconda ci sono $\binom{n}{2}$ termini, tutti uguali a p^2. Sostituendo:

$$\mathbb{E}[X^2] = np + 2\binom{n}{2} p^2.$$

Ora usiamo $\binom{n}{2} = n(n-1)/2$. Il fattore 2 davanti alla somma si semplifica con il denominatore 2:

$$\mathbb{E}[X^2] = np + 2 \cdot \frac{n(n-1)}{2}\, p^2 = np + n(n-1)p^2.$$

Questo è il primo dei due termini necessari per la varianza. Per il secondo, eleviamo al quadrato la media:

$$(\mathbb{E}[X])^2 = (np)^2 = n^2 p^2.$$

Sottraiamo e svolgiamo l'algebra una riga alla volta:

$$\begin{aligned} \operatorname{Var}(X) &= \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \\ &= np + n(n-1)p^2 - n^2 p^2 \\ &= np + (n^2 - n)p^2 - n^2 p^2 \\ &= np + n^2 p^2 - np^2 - n^2 p^2 \\ &= np - np^2 \\ &= \boxed{np(1-p)}. \end{aligned}$$

I due termini $n^2 p^2$ si cancellano. Nei due termini rimasti raccogliamo np, ottenendo la formula finale. Poiché la varianza di ogni singolo bit è $p(1-p)$, il risultato è anche la somma delle n varianze dei bit. Lo abbiamo però ricavato usando l'indipendenza: non possiamo applicare questa conclusione a qualunque somma di indicatrici.

Torniamo ai due modelli del laboratorio. In entrambi contiamo i fallimenti di quattro operazioni, ciascuna con probabilità di fallimento $p = 0{,}2$. La media del conteggio è la stessa:

$$\mathbb{E}[X] = 4 \cdot 0{,}2 = 0{,}8.$$

Nel modello con operazioni indipendenti, X ha distribuzione binomiale. Possiamo usare la formula appena dimostrata. Prima calcoliamo $1 - p = 1 - 0{,}2 = 0{,}8$, poi moltiplichiamo:

$$\begin{aligned}\mathrm{Var}(X) &= 4 \cdot 0{,}2 \cdot 0{,}8 \\ &= 0{,}8 \cdot 0{,}8 \\ &= 0{,}64.\end{aligned}$$

Nel modello del guasto comune, invece, tutte e quattro le operazioni falliscono insieme con probabilità $0{,}2$; altrimenti riescono tutte. Il conteggio può valere soltanto 0 oppure 4:

Fallimenti x	0	4
$P(X = x)$	0,8	0,2

Questo conteggio non segue una distribuzione binomiale. Per trovarne la varianza torniamo alla definizione, usando la media $0{,}8$. Calcoliamo prima gli scarti e i loro quadrati:

$$\begin{aligned}(0 - 0{,}8)^2 &= (-0{,}8)^2 = 0{,}64, \\ (4 - 0{,}8)^2 &= (3{,}2)^2 = 10{,}24.\end{aligned}$$

Ora pesiamo ciascuno scarto al quadrato con la probabilità del corrispondente conteggio:

$$\begin{aligned}\mathrm{Var}(X) &= (0 - 0{,}8)^2 \cdot 0{,}8 + (4 - 0{,}8)^2 \cdot 0{,}2 \\ &= 0{,}64 \cdot 0{,}8 + 10{,}24 \cdot 0{,}2 \\ &= 0{,}512 + 2{,}048 \\ &= 2{,}56.\end{aligned}$$

La varianza del guasto comune è quattro volte quella del modello indipendente: $2{,}56 / 0{,}64 = 4$. La media è rimasta $0{,}8$, ma nel guasto comune il conteggio salta direttamente da 0 a 4: mancano tutti i valori intermedi. Il grafico del laboratorio della Settimana 4 mostra proprio questa concentrazione agli estremi, e la varianza ne misura la maggiore dispersione attorno alla media.

Possiamo anche individuare il passaggio della dimostrazione che qui cambia. Due operazioni fissate falliscono insieme con probabilità $0{,}2$, perché basta che avvenga il guasto comune. Nel modello indipendente, invece, la probabilità dei due fallimenti insieme è $0{,}2 \cdot 0{,}2 = 0{,}04$. Le probabilità singole coincidono, ma quelle congiunte sono diverse: cambiano quindi le medie dei prodotti $I_i I_j$ e, di conseguenza, la varianza del totale.

La linearità del valore atteso vale anche per variabili dipendenti; la somma delle varianze richiede ulteriori condizioni. Per la distribuzione binomiale l'indipendenza giustifica il calcolo dei prodotti e porta a $np(1-p)$. Nel modello del guasto comune dobbiamo invece tenere conto del legame tra le operazioni.

Esercizi: formula la domanda prima di scegliere la formula

Prima di cominciare, un metodo che vale per tutti gli esercizi. Per ognuno, scrivi **prima** tre cose:

1. che cosa conta la variabile;
2. quali valori può assumere;
3. quali ipotesi rendono adatto il modello.

Prova il calcolo prima di aprire la soluzione: un errore che hai fatto e capito insegna molto più di una soluzione letta. I risultati numerici servono a controllare il procedimento.

Esercizio 1 — Esattamente, entro, oltre

Ogni tentativo di una richiesta riesce con probabilità 0,2, indipendentemente dagli altri. X conta i tentativi fino al primo successo. Calcola $P(X = 1)$, $P(X = 2)$ e $P(X = 3)$. Trova poi $P(X > 3)$, $P(X \leq 3)$ e $P(X \geq 3)$, spiegando ciascun evento con una frase.

Soluzione ragionata

Le probabilità puntuali. Prima del successo alla prova k ci sono $k - 1$ fallimenti, quindi i primi tre pesi sono $0{,}2$, $0{,}8 \cdot 0{,}2 = 0{,}16$ e $0{,}8^2 \cdot 0{,}2 = 0{,}128$.

Gli eventi con disuguaglianze. Traduciamo ciascuna frase in una richiesta sui fallimenti.

- «Più di tre» ($X > 3$) richiede che le prime tre prove falliscano: $P(X > 3) = 0{,}8^3 = 0{,}512$.
- «Entro tre» ($X \leq 3$) è il complementare del precedente: $P(X \leq 3) = 1 - 0{,}512 = 0{,}488$.
- «Almeno tre» ($X \geq 3$) richiede soltanto che falliscano le prime due, perché la terza è libera: $P(X \geq 3) = 0{,}8^2 = 0{,}64$.

Controllo. $P(X \leq 3) = 0{,}2 + 0{,}16 + 0{,}128 = 0{,}488$, come sopra. Un errore comune sarebbe aggiungere un fattore $0{,}2$ a $P(X > 3)$: imporrebbe un successo alla quarta prova e cambierebbe la domanda.

Con k tentativi. Lo stesso ragionamento vale per qualunque soglia: «non bastano k tentativi» significa che i primi k falliscono, quindi $P(X > k) = 0{,}8^k$ e $P(X \leq k) = 1 - 0{,}8^k$.

Esercizio 2 — La media e il budget dei tentativi

Con i dati dell'esercizio 1, ciascun tentativo dura esattamente 300 millisecondi. Trova il numero medio di tentativi e il tempo medio senza limite ai retry. Come cambiano con $p = 0{,}5$? Con $p = 0{,}2$, cinque tentativi bastano per raggiungere una probabilità di successo del 99%?

Soluzione ragionata

La media. Con $p = 0{,}2$, $\mathbb{E}[X] = 1/0{,}2 = 5$ tentativi.

Il tempo. Prima convertiamo le unità: 300 millisecondi sono 0,3 secondi. Il tempo totale è $T = 0{,}3X$, quindi per linearità $\mathbb{E}[T] = 0{,}3 \cdot 5 = 1{,}5$ secondi.

Con $p = 0{,}5$. Servono in media $1/0{,}5 = 2$ tentativi e $0{,}3 \cdot 2 = 0{,}6$ secondi. Passando da $p = 0{,}2$ a $p = 0{,}5$ la probabilità di successo per prova viene moltiplicata per 2,5 e la media dei tentativi viene divisa per 2,5.

Il 99%. Cinque è una media, non il budget per il 99%. Infatti $P(X \leq 5) = 1 - 0{,}8^5 = 1 - 0{,}32768 = 0{,}67232$, circa il 67,2%. Per il 99% occorrono 21 tentativi, come nel conto del §8.

Esercizio 3 — Il numero già in ritardo

Assumi estrazioni indipendenti e probabilità $1/18$ di comparsa del 53 a ogni estrazione. Quanto vale l'attesa media? Qual è la probabilità di 18 assenze consecutive a partire da oggi? Dopo 50 assenze già osservate, qual è la probabilità di altre 18

assenze? E la probabilità di uscita alla prossima?

Soluzione ragionata

La media. $1/(1/18) = 18$ estrazioni.

Diciotto assenze da oggi. Significa $X > 18$, quindi la probabilità è $(17/18)^{18} \approx 0{,}3574$.

Dopo 50 assenze. Chiediamo $P(X > 68 \mid X > 50)$, perché 50 assenze già osservate più 18 nuove fanno 68. Il rapporto delle code è $(17/18)^{68}/(17/18)^{50} = (17/18)^{18}$: lo stesso valore di prima, per l'assenza di memoria.

L'uscita alla prossima. Rimane $1/18$. L'attesa futura non cambia; il tempo totale già trascorso (50) resta trascorso.

Esercizio 4 — Convertire l'intervallo

Le richieste seguono il modello di arrivi di Poisson a tasso costante di 3 al secondo. Trova la probabilità di zero richieste in un secondo, in mezzo secondo e in un minuto. Perché non possiamo usare lo stesso λ nei tre conti?

Soluzione ragionata

Il parametro per ciascun intervallo. Usiamo $\lambda = rt$ con $r = 3$ al secondo. Le tre durate danno $\lambda = 3 \cdot 1 = 3$, $\lambda = 3 \cdot 0{,}5 = 1{,}5$ e $\lambda = 3 \cdot 60 = 180$.

Zero eventi. Per zero eventi la formula è $e^{-\lambda}$. Otteniamo circa $0{,}0498$ in un secondo, $0{,}2231$ in mezzo secondo e $6{,}71 \cdot 10^{-79}$ in un minuto.

Perché non lo stesso λ. Il *tasso* resta uguale, ma il *numero medio di richieste* cambia con la durata dell'intervallo. Un minuto senza arrivi è enormemente meno probabile di un secondo senza arrivi. La notazione scientifica rende leggibile il terzo risultato senza scrivere decine di zeri.

Esercizio 5 — Dalla probabilità alla colonna attesa

Con $\lambda = 0{,}61$, parti da $P(X = 0) = e^{-0{,}61}$ e calcola i pesi per 1, 2 e 3 eventi usando la ricorrenza. Quanti corpi-anno con quei conteggi prevedi su 200? Perché il risultato può non essere intero?

Soluzione ragionata

I pesi. Partiamo da circa $0{,}543351$. La ricorrenza dice di moltiplicare per λ/k a ogni passo: per $k = 1$ per $0{,}61$, per $k = 2$ per $0{,}61/2$, per $k = 3$ per $0{,}61/3$. Otteniamo circa $0{,}331444$, $0{,}101090$ e $0{,}020555$.

I numeri attesi. Moltiplichiamo per 200: circa 66,3, 20,2 e 4,1. Le frequenze osservate erano 65, 22 e 3.

Perché non sono interi. I valori attesi sono *medie teoriche* di conteggi interi e non devono essere interi, come il 3,5 del dado. Neppure un modello esatto imporrebbe al campione di coincidere con le proprie frequenze attese.

Esercizio 6 — Calcolare e interpretare una varianza

Una variabile Y vale 0 con probabilità $1/4$, 2 con probabilità $1/2$ e 4 con probabilità $1/4$. Calcola media e varianza **con la definizione degli scarti**. Può avere distribuzione di Poisson? Usa poi lo stesso procedimento per verificare la varianza 0,6079 della tabella di Bortkiewicz.

Soluzione ragionata

La media. $0 \cdot \frac{1}{4} + 2 \cdot \frac{1}{2} + 4 \cdot \frac{1}{4} = 0 + 1 + 1 = 2$.

Gli scarti e la varianza. Gli scarti dalla media sono -2, 0 e 2. Elevati al quadrato e pesati:

$$\operatorname{Var}(Y) = (-2)^2 \frac{1}{4} + 0^2 \frac{1}{2} + 2^2 \frac{1}{4} = 1 + 0 + 1 = 2.$$

Può avere distribuzione di Poisson? Media e varianza coincidono, ma Y **non ha distribuzione di Poisson**: per esempio $P(Y = 1) = 0$, mentre una distribuzione di Poisson di parametro 2 assegna a 1 probabilità $2e^{-2} > 0$. Abbiamo così un controesempio all'idea che l'uguaglianza fra media e varianza identifichi il modello.

Bortkiewicz. I pesi sono le frequenze divise per 200 e la media è 0,61. La somma pesata degli scarti al quadrato è:

$$\frac{109(0 - 0{,}61)^2 + 65(1 - 0{,}61)^2 + 22(2 - 0{,}61)^2 + 3(3 - 0{,}61)^2 + (4 - 0{,}61)^2}{200} = 0{,}6079.$$

Il valore vicino alla media è coerente con il modello, ma non ne prova tutte le ipotesi.

Esercizio 7 — Scegliere il modello e dichiarare le ipotesi

Per ciascuna situazione indica un modello naturale e trova la probabilità richiesta. Quando il testo fornisce soltanto una media, precisa quali ipotesi aggiungi per usare la distribuzione di Poisson.

1. Un collegamento perde in media 0,5 pacchetti al minuto: probabilità di almeno una perdita in un minuto.
2. Ogni connessione riesce con probabilità 0,9, indipendentemente dalle altre: probabilità di dover fare più di un tentativo.
3. Un testo contiene in media 2 refusi per pagina: probabilità di esattamente 2 refusi in una pagina.
4. Fra 10 operazioni indipendenti, ciascuna riesce con probabilità 0,9: probabilità che riescano tutte.
5. **Richiamo facoltativo:** quanti numeri pari ci sono fra i 5 estratti senza reinserimento da 1 a 90? Trova la media e spiega perché il conteggio non segue una distribuzione binomiale.

Soluzione ragionata

1. **Pacchetti persi.** Se le perdite sono eventi singoli, a tasso stabile e senza dipendenza fra intervalli disgiunti, usiamo la distribuzione di Poisson$(0{,}5)$. «Almeno una perdita» ha come complementare «zero perdite», quindi $P(X \geq 1) = 1 - e^{-0{,}5} \approx 0{,}3935$. La sola media non assicura queste ipotesi: le stiamo aggiungendo noi.
2. **Connessioni.** Il numero di tentativi fino al successo è Geometrica$(0{,}9)$. «Più di un tentativo» significa che il primo fallisce: $P(X > 1) = 0{,}1$.
3. **Refusi.** Se adottiamo il modello con distribuzione di Poisson, con esposizione omogenea per pagina e refusi non raggruppati, $P(X = 2) = 2^2 e^{-2}/2! = 2e^{-2} \approx 0{,}2707$. Conoscere la media 2 non basta, da solo, a identificare la distribuzione.
4. **Dieci operazioni.** Il numero di riuscite ha distribuzione binomiale$(10, 0{,}9)$; riescono tutte con probabilità $0{,}9^{10} \approx 0{,}3487$.
5. **Numeri pari.** Il modello è Ipergeometrico. Ci sono 45 pari su 90; dopo ogni estrazione cambia la composizione dei numeri rimasti, quindi le cinque indicatrici non sono indipendenti. Ciascuna ha però media $45/90$. Per linearità, che non richiede indipendenza, la media del totale è $5 \cdot 45/90 = 2{,}5$.

Esercizio 8 — Un picco oltre la soglia

Un conteggio ha distribuzione di Poisson con $\lambda = 2$. Trova la probabilità di almeno tre eventi. Quali proprietà hanno media e varianza? Se una serie di intervalli comparabili avesse media osservata circa 2 e varianza circa 9, che cosa controlleresti?

Soluzione ragionata

Almeno tre eventi. Significa $X \geq 3$, il cui complementare è $X \in \{0, 1, 2\}$. Togliamo da 1 i pesi di 0, 1 e 2:

$$P(X \geq 3) = 1 - e^{-2}\left(1 + 2 + \frac{2^2}{2}\right) = 1 - 5e^{-2} \approx 0{,}3233.$$

Media e varianza. Nel modello valgono entrambe 2.

Una varianza osservata di 9. Suggerirebbe sovradispersione rispetto alla distribuzione di Poisson con media 2. Controllerei se abbiamo mescolato intervalli con tassi diversi, se ci sono raffiche o cause comuni, e quanto è grande il campione. Non basta sostituire λ con 9: in una distribuzione di Poisson quello cambierebbe anche la media.

Errori da evitare: tornare al significato

Ogni errore frequente ha una domanda che lo previene. Quando nel tuo conto compare qualcosa che ti insospettisce, fermati e chiediti la domanda corrispondente.

Se nel conto compare…	Torna a questa domanda
$(1-p)^k p$ per $P(X=k)$ nella nostra Geometrica	Prima del successo alla prova k, quanti fallimenti servono?
Lo stesso esponente per $X > k$ e $X \geq k$	Devo fallire anche la prova k, oppure soltanto le precedenti?
Un fattore p nella coda geometrica	Sto imponendo un successo in una prova precisa?
L'idea che il ritardatario sia dovuto	Sto calcolando una probabilità futura condizionata o quella dell'intera sequenza?
La media trattata come una scadenza	Quale probabilità attribuisce la coda al superamento della media?
λ copiato dal testo senza unità	A quale durata o esposizione si riferisce la domanda?
Una probabilità della distribuzione di Poisson maggiore di 1	Ho distinto il numero medio λ da $P(X=k)$? Ho incluso $e^{-\lambda}$ e $k!$?
«Media uguale a varianza, dunque distribuzione di Poisson»	Ho controllato il meccanismo e le altre probabilità della distribuzione?
«La media osservata deve essere esattamente λ»	Sto distinguendo i dati osservati dalla media del modello?
Una varianza calcolata con scarti che si cancellano	Ho elevato al quadrato ogni scarto prima di fare la media?

Riepilogo per lo studio

Rileggiamo il percorso in poche righe, nell'ordine in cui l'abbiamo fatto.

La varianza. Aggiunge al centro della distribuzione una misura della dispersione. Per calcolarla dalla definizione troviamo la media, gli scarti, i quadrati degli scarti e infine la loro media pesata. La radice della varianza è la deviazione standard, che ha le stesse unità della variabile.

La Geometrica. Nasce quando ripetiamo prove indipendenti con probabilità di successo costante e contiamo tutte le prove fino al primo successo. La PMF $(1-p)^{k-1}p$ descrive una sequenza di $k-1$ fallimenti chiusa da un successo. La coda $(1-p)^k$ richiede soltanto k fallimenti. La media è $1/p$; l'assenza di memoria riguarda la distribuzione dell'attesa che resta dopo i fallimenti già osservati.

La distribuzione di Poisson. Descrive un conteggio in un intervallo. Il modello a pezzetti la costruisce come limite di distribuzioni binomiali con sempre più prove, probabilità per prova sempre più piccola e media totale λ fissata. La sua PMF è $\lambda^k e^{-\lambda}/k!$; media e varianza valgono entrambe λ. Con un tasso costante r e una durata t, il parametro dell'intervallo è $\lambda = rt$.

Le applicazioni. Gli esempi informatici mostrano perché conta formulare la domanda. Per scegliere un budget di retry serve una coda dell'attesa; per stimare quanti intervalli superano una soglia di arrivi serve una coda del conteggio. In entrambi i casi la formula dipende dal modello: indipendenza, stabilità delle probabilità e corretta unità di osservazione devono avere un significato nel sistema studiato.

Prova a raccontarlo senza il formulario

Descrivi che cosa conta la variabile. Costruisci l'evento richiesto con una frase o una sequenza. Spiega dove usi l'indipendenza. Poi scrivi la formula, fai il conto e interpreta il risultato con le unità giuste. Se riesci a ricostruire questi passaggi, stai usando la distribuzione come uno strumento di ragionamento, e non come una formula da ricordare.

Riferimenti e letture

La costruzione della dispensa segue i testi disponibili nella bibliografia del corso. I rimandi alle sezioni permettono di ritrovare i passaggi anche in edizioni con una diversa numerazione delle pagine.

- **Ladislaus von Bortkiewicz**, *Das Gesetz der kleinen Zahlen*, Teubner, 1898, cap. II, §12, pp. 23–25. È la fonte dei dati dei corpi d'armata e della tabella osservati–attesi. Copia di lavoro: `bibs/classics/Bortkiewicz_1898_Das_Gesetz_der_kleinen_Zahlen.pdf`; scansione pubblica.
- **Siméon-Denis Poisson**, *Recherches sur la probabilité des jugements en matière criminelle et en matière civile*, Bachelier, Parigi, 1837. È l'opera in cui compare l'approssimazione che oggi porta il suo nome; qui serve come motivazione storica. Scansione pubblica. Che il titolo di Bortkiewicz richiami la legge dei grandi numeri di Poisson, senza contrapporvisi, è indicato nella voce «Bortkiewicz, Ladislaus von» dell'*Encyclopedia of Mathematics*.
- **Michael Baron**, *Probability and Statistics for Computer Scientists*, 2ª ed., CRC Press, 2014, §3.4.3, «Geometric distribution», e §3.4.5, «Poisson distribution»; per la varianza, §3.3.4. Copia di lavoro: `bibs/tech/baron2014probabilityforcs.pdf`. Il testo usa la convenzione geometrica che conta anche la prova riuscita.
- **Chris Piech**, *Probability for Computer Scientists*, materiale del corso Stanford CS109, copia in `bibs/tech/Piech2023ProbabilityForCSs.pdf`: voci «Variance», «Geometric Random Variable», «Poisson Distribution» e «Binomial Approximation». La costruzione attraverso suddivisioni dell'intervallo è ripresa con spiegazioni autonome in questa dispensa. Portale del testo.
- **Burton H. Bloom**, «Space/time trade-offs in hash coding with allowable errors», *Communications of the ACM*, 13(7), 1970, pp. 422–426. Riferimento originale dell'approfondimento sul filtro; scheda dell'articolo.
- **Il 53 di Venezia:** l'episodio è una motivazione storica, non un dato necessario ai calcoli. Per la cronaca del ritardo di 182 estrazioni, si veda *l'Unità*, 12 giugno 2005, p. 10, già indicata nella bibliografia della lezione. Il modello probabilistico è dichiarato nel testo e non dipende dalle interpretazioni giornalistiche dell'episodio.